Treball d'Innovació:
Detecció de metàstasi mitjançant CNN + NCRF

Xavier Martín Ballesteros, Xavier Lacasa Curto, Antoni Rambla Moiset

Maig 2019

UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH

Contents

1 Introducció **2**

2 Descripció de les tècniques de IA **2**
2.1 Convolutional Neural Networks . . . 2
2.1.1 Convolutional layers . . . 3
2.1.2 Hidden Layers . . . 4
2.1.3 Classifier . . . 7
2.2 Conditional Random Field . . . 8

3 L'arquitectura NCRF **8**

4 Resultats **9**

5 Innovació **10**
5.1 Explicació de la innovació . . . 10
5.2 Naturalesa de la innovació . . . 10

6 Impacte empresarial **10**
6.1 Beneficis . . . 10
6.2 Riscs . . . 11
6.3 Posició en el mercat . . . 11

7 Impacte social **11**
7.1 Beneficis . . . 11
7.1.1 Medicina . . . 11
7.1.2 Tecnologia i Investigació . . . 12
7.2 Riscs . . . 12

8 Projectes similars **12**
8.1 Versió de Google . . . 12
8.2 Human / unsupervised . . . 13

9 Conclusions **13**

10 Bibliografia **14**

1 Introducció

En l'actualitat es coneixen diversos mètodes per a diagnosticar el càncer, la més segura i usada és l'anàlisi de teixit extret. Aquesta, però, no és una tasca senzilla.

Per a la deteccio de cancer de mama, normalment es necesita analitzar el teixit mitjançant WSI (Whole Slide Imaging)[1]. Aquest tipus d'imatges es caracteritzen per ser molt grans. Una magnificació (40x) de la imatge normalment conté bilions de píxels, i pot ocupar uns quants gigabytes de memòria. En aquestes imatges immenses, els patòlegs han d'analitzar cada part de la imatge en cerca de micro-metàstasis, petites agrupacions de cèl·lules que són un signe primerenc pel càncer. Aquestes cèl·lules poden tenir un diàmetre de 1000 píxels. Tot això fa que l'anàlisi d'aquest tipus d'imatges sigui molt complex i consumeixi molt de temps.

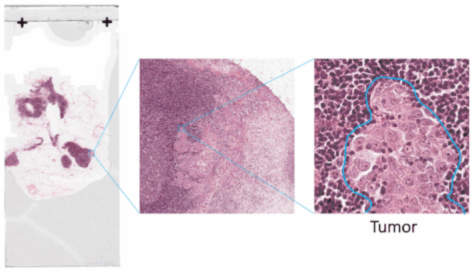

Figure 1: Representació d'una imatge WSI i la descomposició en diverses subimages fins acabar trobant el tumor.

L'ús de deep learning mitjançant deep Convolutional Neural Networks (CNN) no és nou però com que la imatge és tan gran, aquesta s'ha de dividir en segments per a poder ser processada. Aquesta tècnica pot portar problemes, ja que no es té en compte la correlació espacial que hi ha entre grups d'imatges veïnes. És pot donar el cas en què un tumor que estigui dividit en dues o més seccions no es detecti. Degut a això, l'empresa Baidu proposa una tècnica que analitza una secció tenint en compte la correlació espacial amb les seves imatges veïnes. Gràcies a això, aconsegueixen minimitzar la quantitat de falsos negatius. Aquest nou model l'han anomenat NCRF (Neural Conditional Random Field).

2 Descripció de les tècniques de IA

2.1 Convolutional Neural Networks

Les Convolutional Neural Networks (CNNs) són un cas particular de deep learning. La seva arquitectura està dissenyada per treure profit de l'estructura de les imatges. Poden reconèixer patrons amb una variabilitat molt gran i amb robustesa a les distorsions i transformacions geomètriques simples.

La seva arquitectura es divideix en diverses seccions, l'última de les quals segueix l'estructura bàsica de xarxa neuronal. Comencem però, per la primera: les Convolutional Layers.

[1] Whole slide imaging (WSI), es refereix a l'escaneig dels panels de vidre convencionals per tal de digitalitzar-les, aquest modelatge és el més recent i més usat pels departaments de patologia arreu del món.

2.1.1 Convolutional layers

Aquestes són capes que efectuen convolucions sobre l'input que reben i passen el resultat de la convolució a la següent capa.

Per a entendre el concepte de convolució primer necessitem saber què és un filtre o kernel. Això és simplement una matriu quadrada (de mida a triar). La convolució consisteix en fer passar aquest filtre per tota la imatge (la imatge no és res més que una altra matriu), calculant el producte vectorial entre el kernel i la regió de la imatge de la mateixa mida per on està passant el kernel. El resultat d'això es guarda en una nova matriu, en la posició on estava centrat el filtre. Això dóna lloc a una nova matriu amb els resultats de la convolució. Aquesta nova matriu serà una mica més petita que l'input, ja que el kernel té amplada i alçada i no pot sortir de la imatge, de manera que perdem les vores. El contingut d'aquesta seran valors alts allà on moltes cel·les del kernel amb valors alts han coincidit amb cel·les de la matriu input amb valor alt, i valors baixos del contrari. D'aquesta manera, si teniem un kernel format per:

$$K = \begin{bmatrix} 0 & 8 & 8 & 0 & 0 \\ 0 & 8 & 8 & 0 & 0 \\ 0 & 8 & 8 & 0 & 0 \\ 0 & 8 & 8 & 0 & 0 \\ 0 & 8 & 8 & 0 & 0 \end{bmatrix}$$

El resultat de la convolució serà una matriu amb valors alts allà on hi havia formes altes.

Aquesta matriu resultant es pot tornar a utilitzar com a input per una altra capa de convolució, ja que al ser una matriu de números, el format és el mateix que el d'una imatge. D'aquesta manera, podem anar encadenant la búsqueda de diferents formes per buscar estructures més abstractes: si després de trobar elements alts a la imatge, busquem elements allargats, podem trobar creus a la imatge, entre d'altres coses).

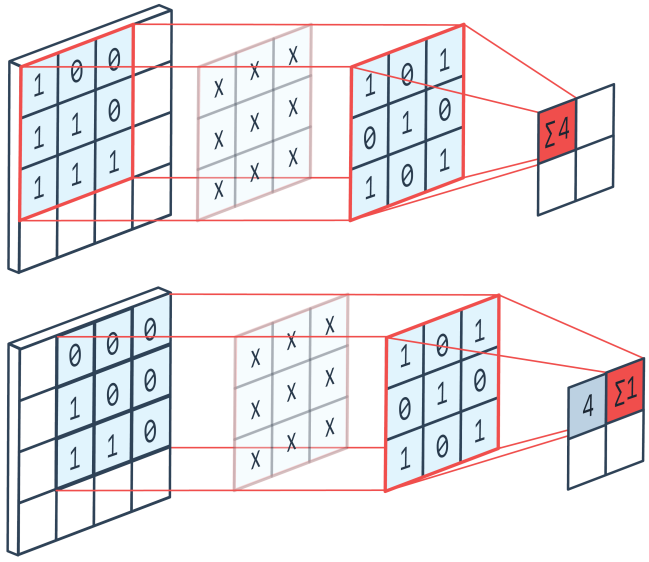

Figure 2: Convolution

Normalment, però, per diversos motius (com que la matriu resultat acostuma a ser sparse, per

accel·lerar l'entrenament i inferència, reduir la mida, etc.) entre capes de convolució s'introdueixen Pooling Layers. Aquestes el que fan es reduir la mida de la matriu "fusionant" unes quantes cel·les en una de sola. Per fer-ho hi ha diversos mètodes: el més comú és l'anomenat MaxPooling.

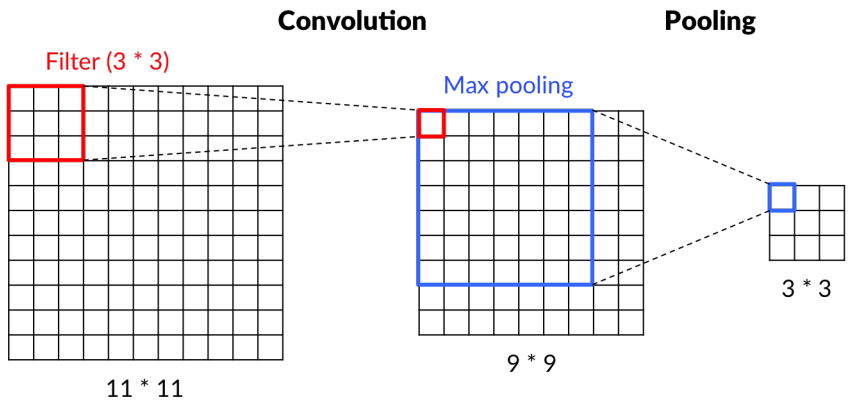

Figure 3: Pooling

MaxPooling consisteix en sel·leccionar el valor més gran de cada grup de cel·les de la matriu i eliminar la resta. D'aquesta manera, si volem reduir la mida de la matriu a 1/4 de l'original, el que faríem seria, per cada grup de 4 cel·les, quedar-nos amb la de valor més gran. Si analitzem això, el que estem fent és substituir la localització exacta de les features per una aproximació de la secció de la imatge on es troben, la qual cosa ens permet no haver d'emmagatzemar tanta informació per representar-ho.

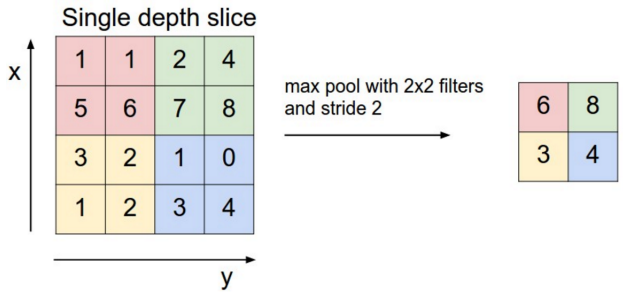

Figure 4: MaxPooling (stride és el desplaçament)

Aquesta combinació de Convolutional Layer + MaxPooling + Convolutional Layer + MaxPooling + ... és usada amb freqüència en les CNNs. Cal remarcar que no són suficients per si soles, i després d'aquestes venen les capes tradicionals de les xarxes neuronals: les Hidden Layers.

2.1.2 Hidden Layers

Les Hidden Layers són capes formades per neurones connectades amb neurones de la capa anterior i de la capa següent. D'aquesta manera, una neurona rep l'output de neurones de la capa anterior, l'hi aplica una funció i passa el resultat a la següent capa. Concretament, l'output de cada neurona de

la capa anterior és multiplicat per un pes específic per cadascuna; els resultats són sumats i això és el que rep la neurona de la capa següent. No obstant, aquesta neurona no té perquè rebre output de totes les neurones de la capa anterior, les connexions formen part de les característiques modificables d'una xarxa neuronal i varien en diferents arquitectures.

A continuació la neurona agafa aquest input i el passa per la seva funció d'activació. La funció és, un cop més, específica de cada arquitectura, però acostuma a ser Lineal, Sigmoid, ReLU, Tangent, etc. (no les explicarem totes ja que només cal buscar la fórmula per entendre-les). El resultat de la funció llavors, es treu com a output i es passa a totes les neurones de la següent capa amb les que estigui connectada (per cada connexió l'output és multiplicat per un pes diferent, tal i com passava amb l'input d'aquesta neurona). El procés es va repetint per tantes capes com es tinguin.

Figure 5: Connexió entre neurones

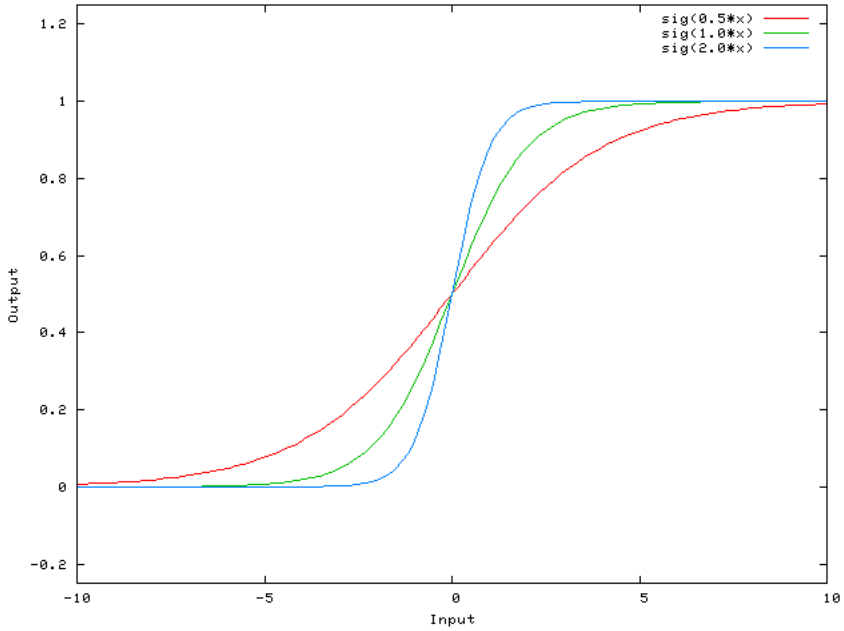

Figure 6: Funció Sigmoid d'una neurona amb una sola neurona de la capa anterior com a input. Es mostra com varia l'output de la funció si variem el pes de la connexió de l'input.

Aquesta és la teoria general, però a les CNNs predomina un tipus d'arquitectura: Fully Connected Layers amb ReLU. Això vol dir que majoritàriament s'utilitzen capes on cada neurona es connecta amb totes les neurones de la següent capa i, com a funció apliquen ReLU. ReLU (Rectified Linear Unit) és una funció molt simple però efectiva: $max(0, input)$. El seu poder recau en no ser una funció lineal. El fet d'utilitzar una funció lineal obre moltes portes a l'hora de fer prediccions, però l'efecte es multiplica quan ajuntem múltiples capes, cadascuna amb múltiples neurones (les connexions de les quals es poden triar), cadascuna amb una funció no lineal (l'output de les quals pot ser modificat multiplicant-lo pel pes de les connexions): el resultat és que és possible crear qualsevol funció. La teoria de les xarxes neuronals diu que amb prous capes i neurones, és possible recrear qualsevol funció, i per tant, trobar un patró que s'adapti a totes les dades. En part per això

les xarxes neuronals tendeixen a fer overfitting. És molt fàcil que per minimitzar l'error modifiquin la funció que representen per a ajustar-se a les dades d'entrenament a la perfecció, cosa que resulta en una capacitat de predicció pobre per dades que no ha vist.

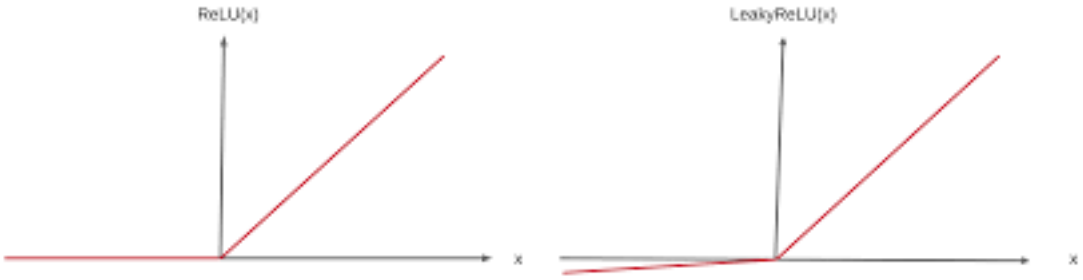

Figure 7: Funció ReLU i LeakyReLU. LeakyReLU fa referència a crear una funció lineal per valors negatius en comptes de posar-los a 0. La recta creada segueix assolint valors molt propers a zero, però resol un problema relacionat amb Backpropagation degut a que la derivada de ReLU val zero si ens trobem en valors negatius i això causarà que no es propagui l'error i que aquesta neurona no aprengui.

Segueix faltant un element, i és que no n'hi ha prou amb modificar l'input de la neurona anterior multiplicant-lo per un pes: això no crea tota la variabilitat que volem per a poder generar qualsevol funció. La realitat és que les ReLU faran que qualsevol nombre negatiu sigui zero, i els positius els deixarà igual. Però i si volem que tant els negatius com els nombres menors a 10 els transformi en zero? No podríem. Per això a cada capa se li sol afegir una neurona que no rep inputs de cap capa anterior i que sempre passa el valor 1 a les neurones amb les que es connecta. Aquesta neurona es diu Bias, i el seu objectiu és que l'1 que envia, és multiplicat pel pes de la connexió amb la neurona a la que ho envia, de manera que a la pràctica és capaç de enviar qualsevol nombre a les neurones que té connectades (com que el pes de la connexió el determinarà l'aprenentatge, concretament el procés de Backpropagation, serà l'òptim per aquella neurona). Com hem dit anteriorment els inputs d'una neurona es sumen, de manera que si una neurona rebia una suma de 10 de la capa anterior sense bias, amb la neurona de bias i una connexió amb pes 5, rebrà un 15. Així aconseguim que tots els valors que rep aquesta neurona estiguin desplaçats +5, i és equivalent a que haguéssim convertit la ReLU en $max(-5, input)$, com veiem a la figura 9. Amb aquesta modificació la xarxa neuronal sí serà capaç de crear qualsevol funció i obtenir el màxim potencial d'aquesta arquitectura.

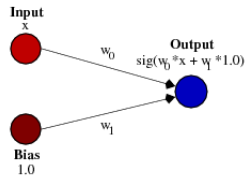

Figure 8: Neurones connectades amb bias

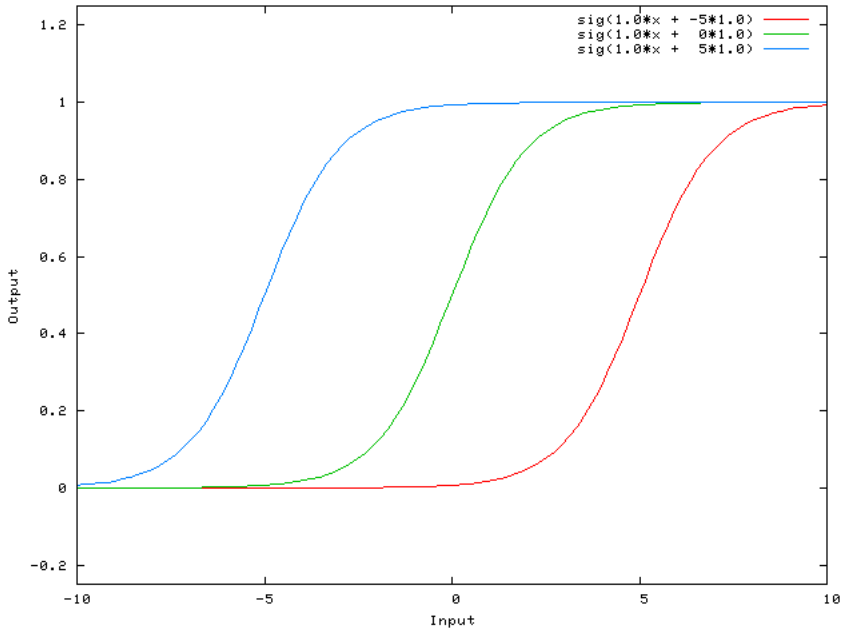

Figure 9: Funció Sigmoid (no ReLU, però l'efecte és el mateix) amb diferents bias. Veiem com el resultat és el desplaçament lateral de la funció d'activació.

Falta dir, encara, com es connecta l'última Convolutional/MaxPooling Layer amb la primera Fully connected Layer. El procés és molt senzill, cada cel·la de la matriu resultant es connecta amb les neurones de la capa. Ens ho podem imaginar com si aplanéssim la matriu en una llista d'una dimensió i mida ROWS*COLS. Ara és fàcil imaginar-se que cada una d'aquestes posicions de la llista actua com una neurona que transmet el seu valor a les de la següent capa.

Amb això aclarat, només queda veure com passar de capes de neurones a un output que classifiqui la imatge inicial. Això es fa en una sola capa, l'ultima, que anomenarem Classifier.

2.1.3 Classifier

Aquesta última capa serà l'encarregada de rebre l'output de l'última Fully Connected Layer i interpretar-lo per a triar la caregoria a la que pertany la imatge. En el cas de classificadors normalment el problema es redueix a si és una classificació binària utiltiza una funcio Sigmoid; si té més de 2 categories, Softmax. No entrarem en detalls amb les fórmules per no allargar massa el document, però generalitzat, Sigmoid és la funció de les Figures 9 i 6, i retorna valors molt propers a 0 o 1 excepte quan estàs molt aprop del punt d'inflexió; per això és molt útil per a classificar binàriament. Softmax en canvi retorna, per a cada categoria, la probabilitat que la imatge hi pertanyi (la suma de les probabilitats de totes les categories sempre és 1 per totes les imatges). Per a problemes de classificació de diversos objectes en una mateixa imatge aquesta última capa es complica, però queda fora del domini d'aquest treball.

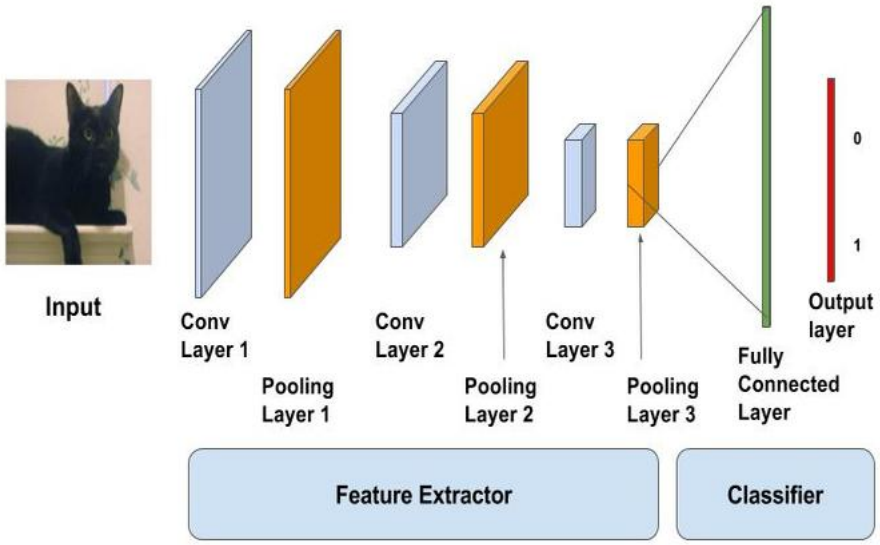

Figure 10: Estructura d'una CNN.

És fàcil, ara, veure com l'estructura general que segueix una CNN és la de la Figura 10.

2.2 Conditional Random Field

Els Conditional Random Fields (CRFs) són un model estocàstic normalment utilitzat en el reconeixement de patrons. Utilitzen informació contextual i, en conseqüència, el model té molta més informació per a fer una predicció correcta. S'utilitzen per codificar relacions conegudes entre observacions i construir interpretacions consistents i s'utilitzen sovint per etiquetar o analitzar dades seqüencials.

Mentre que un classificador discret fa prediccions sense tenir en compte les mostres veïnes, els CRFs sí que les tenen en compte. És a dir, les CRFs tenen en compte el context. La idea de les CRFs és la de definir una distribució de probabilitat condicional sobre seqüències d'etiquetes a partir d'una seqüència particular d'observacions. L'avantatge principal sobre els models ocults de Markov (HMMs) és la naturalesa condicional, el que resulta en la relaxació de les hipòtesis d'independència requerides pels HMMs per tal d'assegurar una inferència traçable.

A més, les CRFs eviten el problema de *bias* d'etiquetes, que apareix en tots els models gràfics dirigits.

Els detalls i la implementació d'aquests models els considerem que estan fora de l'abast del coneixement que disposem actualment i per tant, no entrarem en una explicació detallada del funcionament d'aquest.

3 L'arquitectura NCRF

L'arquitectura que han creat l'han anomenat NCRF (Neural Conditional Random Field). La idea principal de la NCRF és agafar una quadrícula de subimatges com a entrada (per exemple, 3x3) i utilitzar una CNN per extreure les característiques d'aquestes imatges. Cal remarcar que no han posat una última capa de classificació a la CNN, de manera que el NCRF treballa amb directament amb les features extretes de cada imatge. A continuació, utilitzen un model CRF per combinar aquestes features i així crear prediccions de la imatge en qüestió basada en la informació del voltant.

D'aquesta manera, segons Yi Li "Nosaltres permetem a l'algorisme fer un *zoom out*" i "D'aquesta manera permetem examinar el context de la imatge".

El model de la CNN que s'ha agafat és una modificació de l'estàndard ResNet, creat per *torchvision*. La diferència principal es troba en el *forward pass* (procés de càlcul de la sortida a partir de l'entrada de l'algorisme):

- El tensor d'entrada té una dimensió més.
- Utilitza el mòdul CRF per suavitzar el *logit* (funció que retorna la probabilitat de pertànyer a una categoria) de cada subimatge utilitzant els seus *embeddings*.

El model CRF només té un paràmetre entrenable, W, pel potencial entre subimatges. Quan el model està ben entrenat, W típicament reflexa la posició espacial relativa entre diferents subimatges dins la quadrícula.

Com podem veure en la figura 11, tenim un valor de sortida que indica la probabilitat que la quadrícula d'entrada contingui algun conjunt de cèl·lules potencialment cancerígenes.

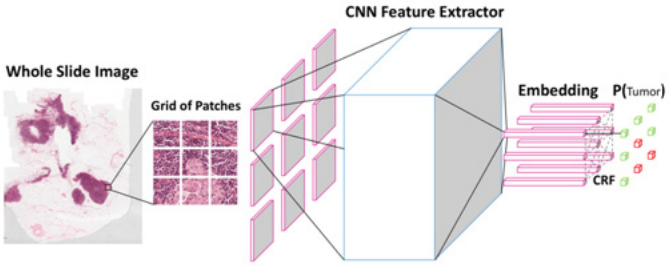

Figure 11: Representació del model NCRF.

Afortunadament, l'algorisme és *Open Source*, i es pot trobar a GitHub [3], amb l'esperança d'avançar en la investigació de la intel·ligència artificial en l'anàlisi de patologies.

4 Resultats

Hi ha una competició anomenada Camelyon16 en la que s'evaluen nous i existents algorismes automàtics per la detecció de metàstasis. En les imatges de test proporcionades per aquesta competició, el model NCRF va aconseguir una puntuació de 0.8096, superant tant a un patòleg professional, amb una puntuació de 0.7240, com al guanyador de la competició, amb una puntuació de 0.8074.

En la següent figura podem observar com l'anàlisi que fa el model NCRF (d) conté molts pocs falsos positius a part de les regions òbvies en les que hi ha cèl·lules cancerígenes.

Tot i això hem de tenir en compte que aquest algorisme està pensat per a ressaltar possibles zones cancerígenes per a ajudar als patòlegs professionals a determinar si és un cert o un fals positiu, ja que és molt més fàcil analitzar la part ja processada que tota la imatge, reduint dràsticament el temps d'anàlisi de la imatge i augmentant la qualitat de la detecció de metàstasis. És, doncs, una eina perfecta per incorporar en el treball dels patòlegs.

Tot i que les dades per entrenar el model han estat principalment pel càncer de mama, Yi Li assegura que l'algorisme és una tècnica general que funcionaria en altres tipus de càncer.

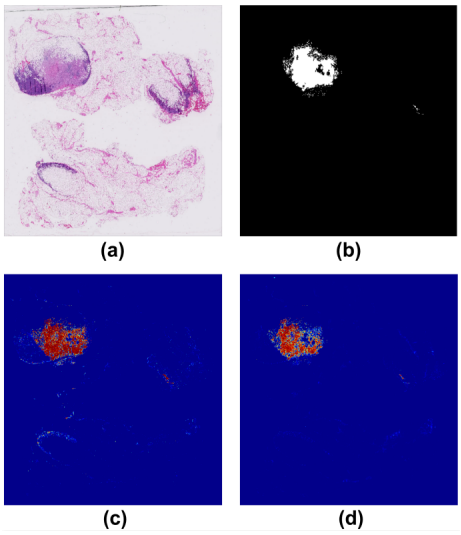

Figure 12: (a) és la imatge original, (b) és l'anàlisi fet per un patòleg professional, (c) és la regió on preveu metàstasis un algorisme que no considera regions veïnes i (d) és el resultat obtingut amb el model NCRF.

5 Innovació

5.1 Explicació de la innovació

Hi ha molts algorismes que s'utilitzen per la detecció de metàstasis en una imatge WSI. El que fa únic a aquest model és que pot mirar a múltiples imatges simultàniament per tenir un context del seu voltant. Aquesta innovació ja s'havia utilitzat en el *sequence labeling* i *semantic image segmentation*, però és la primera vegada que s'utilitza en els algorismes per la detecció de càncer.

Aquesta peculiaritat redueix significativament el nombre de falsos positius en forma de cèl·lules normals mal classificades.

5.2 Naturalesa de la innovació

La naturalesa de la innovació és més aviat de la utilització de tècniques ja existents, perquè les Convolutional Neural Networks i els Conditional Random Fields ja existien. Per tant, com hem dit, la innovació ha consistit en combinar aquestes tècniques per a la detecció de metàstasis.

6 Impacte empresarial

Baidu és una empresa multinacional fundada el 2000 a Pequín, a la Xina. El seu focus principal és el servei de productes relacionats amb l'internet i la intel·ligència artificial. Per a la investigació en aquest últim camp esmentat, Baidu empra científics de tot el món en els seus centres de Beijing, Seattle i Silicon Valley. El desenvolupament de la tecnologia esmentada en aquest treball és un dels molts projectes *Open Source* en els quals treballen els seus investigadors.

6.1 Beneficis

El fet d'experimentar i descobrir els bons resultats que dóna la NCRF tal com s'explica en el paper publicat per Baidu [1], fa que aquesta combinació entre CNNs i CRFs es pugui utilitzar en altres

camps fora de la detecció de metàstasis, ja que és una tècnica que es pot aplicar a qualsevol problema que requereixi visió per computador. Al ser Baidu una empresa amb múltiples investigacions en la intel·ligència artificial, segur que en podrà treure profit en alguna d'elles.

Al haver fet *Open Source* el codi del model NCRF, la gent pot utilitzar-lo lliurament i, a més, fer-li millores. Això genera un impacte clarament positiu envers al públic, ja que mostra altruisme i dedicació en ajudar a la gent.

Per altra banda, el fet d'haver obtingut el millor resultat en la competició Camelyon16 fa que molts inversors s'interessin més per l'empresa i decideixin invertir en ella. Conseqüentment, al tenir més diners, l'empresa pot realitzar més projectes d'investigació, a part de seguir millorant els projectes que ja té, com ara el propi model NCRF.

6.2 Riscs

Com ja hem dit prèviament, aquesta tecnologia és *Open Source*, a més que el paper és públic per a qualsevol que vulgui llegir-l'ho per a entendre en profunditat com va. Això és negatiu per l'empresa, ja que ha hagut d'invertir temps i recursos en la investigació i desenvolupament d'aquesta tecnologia sense que aquesta pugui tornar beneficis sent llogada o venuda com a producte.

6.3 Posició en el mercat

Al ser un producte de lliure accés per a qualsevol usuari o empresa, fa que no tingui un lloc en el mercat, ja que no es pot vendre. Tanmateix, el fet que hagi obtingut la millor puntuació en el *dataset* Camelyon16 fa que aquest model sigui un referent quant a la detecció de metàstasis per mitjà de l'intel·ligència artificial.

Encara que no hi hagi competició per a una millor posició respecte d'altres tecnologies, el fet que diversos investigadors de fins i tot diferents empreses, es puguin unir per a millorar aquesta tecnologia, pot ser una bona base per a crear una potent tecnologia que es pugui convertir en un útil producte i, d'aquesta manera, comercialitzar-lo.

7 Impacte social

7.1 Beneficis

7.1.1 Medicina

Els beneficis per a la societat són clars. Qualsevol millora en la localització de tumors en imatges gegants i en la reducció de falsos positius és un gran pas per a poder arribar a tractar als pacients amb molta antelació.

Quan es diagnostiquen els tumors a temps i es combinen amb el tractament adequat, la probabilitat de supervivència després de 5 anys és dràsticament major que quan es detecta en una etapa posterior, quan el tumor s'ha disseminat i la malaltia està més avançada. A més, també pot reduir significativament el cost del tractament [4]. Estudis en països amb ingressos alts mostren que les despeses pels pacients amb càncer que es diagnostiquen de forma primerenca són de 2 a 4 vegades menys costosos que el tractament de les persones diagnosticades amb càncer en una etapa més avançada.

Cal remarcar que la puntuació en la detecció de tumors (FROC[2]) obtinguda per l'arquitectura NCRF (0.8096) és molt millor que l'obtinguda per un patòleg professional (0.7240). Això fa que l'NCRF sigui una eina més que pot usar el patòleg per detectar més ràpid i millor els tumors. Per altra banda, tot i que la millora respecte al guanyador anterior del repte Camelyon16 sigui molt

[2]La curva FROC es defineix com el gràfic de sensibilitat enfront de la mitjana de falsos positius per imatge.

petita, una diferència de 0.0022 fa que gent a la que abans no se li hagués diagnosticat el tumor (fals negatiu) ara sí se li pugui diagnosticar.

7.1.2 Tecnologia i Investigació

El fet que el codi de l'arquitectura NCRF sigui *Open Source* fa que futures persones puguin ajudar a millorar-la per tal d'aconseguir unes puntuacions majors, ja sigui modificant-la o afegint-la com a una component més d'una arquitectura més gran.

A més, veure que amb la combinació entre medicina i *machine learning* s'arriba a millorar bastant la detecció de tumors (tant en fiabilitat com en rapidesa) pot portar a una gran quantitat de científics a investigar més profundament en aquest món. D'aquesta manera, molta més gent pot aportar el seu granet de sorra, i això provocaria una investigació molt més potent.

7.2 Riscs

Tot i que en un primer moment sembli que un algorisme que aconsegueix detectar millor cèl·lules potencialment cancerígenes en menys temps no tingui cap desavantatge envers la població, sí que en pot arribar a tenir cap als patòlegs i, de manera col·lateral, acabar sent un risc per a la societat.

Un risc notable és intentar dependre massa d'aquestes tecnologies, encara que donin millors resultats que un professional. El fet d'estar entrenades en fer un únic treball és el punt fort i dèbil alhora. Un professional pot trobar altres coses que no siguin una metàstasi però que també podrien ser altament perjudicials per a la salut, mentre que la màquina només se centra en l'únic que sap fer: detectar cèl·lules que podrien arribar a convertir-se potencialment en cancerígenes. Tristament molta gent creu que amb tecnologies tan eficients, a la mínima que donen millors resultats que un patòleg professional, aquest ja és reemplaçable.

També pot passar que els professionals es tornin massa laxos. Com acabem de comentar, un professional humà ha de donar el vist-i-blau del que ha processat la màquina. Tanmateix, es poden arribar a donar casos en els quals hi ha un pacient amb diversos problemes greus i, com el professional es refia del que farà la màquina, aquest només analitza la part ressaltada per l'algorisme, obviant la resta.

Com s'ha esmentat prèviament, la millora respecte a les tècniques de visió per computador per a que cada cop siguin més precises i amb menys error pot arribar a ser usat amb fins maliciosos. Un dels més genèrics per exemple és l'espionatge, el fet de poder detectar coses que mesuren píxels dins d'una imatge de gigabytes pot arribar a ser inclús perillós depenent de les intencions.

8 Projectes similars

8.1 Versió de Google

Google també ha participat en la carrera per al desenvolupament del millor algorisme i tècniques per a la detecció de metàstasis.

Anomenat LYNA (Lymph Node Assistant), aquest assistent ha aconseguit discernir imatges que contenen metàstasis de les quals no un 99% de les vegades. A més a més, té una puntuació FROC de 0.73 si no li permetem falsos positius, en cas que sí que permetéssim, amb un màxim de 8 falsos positius es situa en una puntuació de 0.92. LYNA va començar essent un algorisme genèric de deep learning com per exemple GoogLeNet, el fet que a primeres ja funcionava bé, encara que amb molt de soroll en les imatges, va demostrar que es podien entrenar a models els quals podien igualar o inclús millorar el rendiment de professionals que tenen temps il·limitat per a analitzar les imatges.

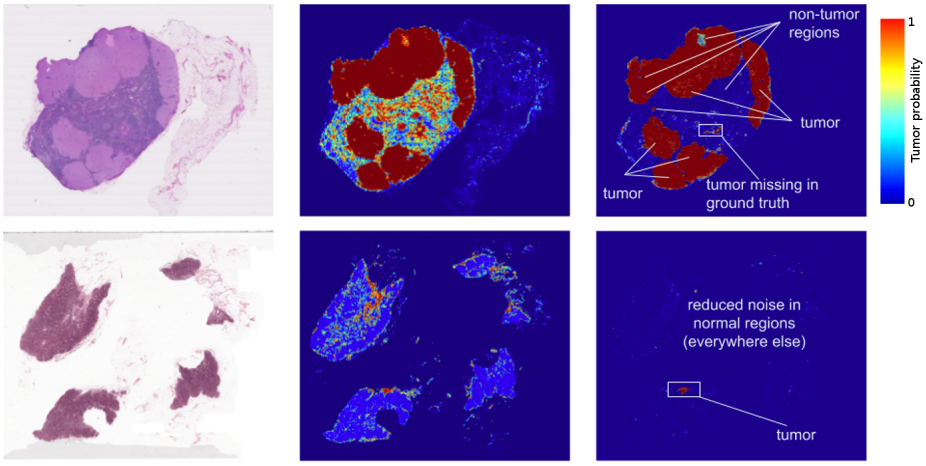

Figure 13: Analisi de un tumor pels algorismes tant basic com el millorat

La imatge del centre és l'anàlisi fet per l'algorisme genèric, com podem veure no és del tot erroni però com ja hem comentat abans conté molt soroll, el de la dreta en canvi és el ja millorat, es pot apreciar que és molt més clar i simple veure les regions conflictives.

8.2 Human / unsupervised

Hi ha poca informació d'aquest grup d'investigadors, l'únic que es dóna a saber és el nom d'un expert en deep learning, Antonio de Perio.

Entrenat mitjançant una versió simplificada del dataset Camelyon16 anomenat PCam (PatchCam), el qual és un subset de Camelyon16 el qual conte aproximadament 300,000 imatges sense duplicats i amb resolució baixa, i usant una CNN anomenada Resnet50 com a component principal afirmen poder trobar, en aquest mateix dataset, possibles cancers amb una precisió del 98.6% .

9 Conclusions

Com hem pogut observar, el fet de mesclar tècniques ja existents i analitzar els resultats pot ser molt útil a l'hora d'intentar crear noves tècniques en la visió per computació. Encara que sembla que Baidu no ha seguit investigant i desenvolupant aquestes tècniques, el fet que s'han creat demostra que poden haver moltes combinacions possibles a l'hora d'abordar problemes d'aquest calibre.

El fet que una gran empresa com Baidu ajudi en el desenvolupament de tecnologies d'aspecte mèdic i a més a més publiqui els resultats com a codi open source demostra una gran consciència social i una dedicació a voler ajudar a desenvolupar la IA.

Per a acabar cal remarcar que una millora en les tècniques i en els recursos que tenen els patòlegs per a la detecció de metàstasi beneficia enormement a la població, ja que un tractament preventiu o en etapes inicials és molt simple i poc costós, tant econòmicament com físicament.

10 Bibliografia

References

[1] Li, Y. i Ping, W. *Cancer Metastasis Detection With Neural Conditional Random Field* (April 11, 2018). [Consulted: March 15, 2019].

[2] Baidu. *Using Deep Learning to Help Pathologists Find Tumors* [online]. (June 18, 2018). http://research.baidu.com/Blog/index-view?id=104 [Consulted: March 15, 2019].

[3] Baidu. *NCRF* [online]. (June 4, 2018). https://github.com/baidu-research/NCRF [Consulted: March 15, 2019]

[4] OMS. *Early cancer diagnosis saves lives, cuts treatment costs* [online]. (February 3, 2017). https://www.who.int/es/news-room/detail/03-02-2017-early-cancer-diagnosis-saves-lives-cuts-treatment-costs [Consulted: April 2, 2019].

[5] Camelyon16. *ISBI challenge on cancer metastasis detection in lymph node* [online]. (April 13, 2016). https://camelyon16.grand-challenge.org/Results/ [Consulted: April 17, 2019].

[6] Google. *Applying Deep Learning to Metastatic Breast Cancer Detection* [online]. (October 12, 2018). https://ai.googleblog.com/2018/10/applying-deep-learning-to-metastatic.html [Consulted: April 29, 2019.].

[7] Google. *Assisting Pathologists in Detecting Cancer with Deep Learning* [online]. (March 3, 2017). https://ai.googleblog.com/2017/03/assisting-pathologists-in-detecting.html [Consulted: April 29, 2019].

[8] human / unsupervised. *Histopathological Cancer Detection* [online]. (n.d.). https://www.humanunsupervised.com [Consulted: April 30, 2018].

[9] Stack Overflow. *Role of Bias in Neural Networks* [online]. (October 12, 2018). https://stackoverflow.com/questions/2480650/role-of-bias-in-neural-networks [Consulted: March 15, 2019.].

[10] Medium. *Overview of Conditional Random Fields*[online]. (Aug 7, 2017). https://medium.com/ml2vec/overview-of-conditional-random-fields-68a2a20fa541 [Consulted: March 24, 2019].

[11] Aurélien Géron *Hands-On Machine Learning with Scikit-Learn and TensorFlow* (March 13, 2017). [Consulted: March 25, 2019].