Google Duplex

Inteligencia Artificial al otro lado del teléfono

Ariosa Hernández, Roberto
Bosch Llufriu, Julia
Gómez Sánchez, Joaquim

QT - 2018/2019

Índice

1. El producto y su contexto 2
2. Descripción de las técnicas de IA 3
   2.1. Recurrent Neural Network 3
   2.2. Text To Speech con WaveNet - Convolutional Neural Networks y Generative Adversarial Networks 5
   2.3. Text To Speech con Tacotron 2 8
3. Descripción de la utilización de las técnicas 10
4. Innovación 11
   4.1. Explicación de la innovación 11
   4.2. Naturaleza de la innovación 11
5. Impacto Social 12
   5.1. Beneficios 12
   5.2. Riesgos 12
6. Impacto Empresarial 14
   6.1. Beneficios 14
   6.2. Riesgos 14
   6.3. Posición en el mercado 15
7. Conclusión 16
8. Referencias 17

EL PRODUCTO Y SU CONTEXTO

La empresa Google presentó su asistente virtual para dispositivos móviles en mayo del 2016. Este, Google Assistant, que cualquier persona puede inicializar en un dispositivo con sistema operativo Android diciendo “Ok, Google”, nació para competir con el asistente virtual de Apple, Siri.

Google Assistant vino a sustituir también al anterior asistente virtual de la empresa, Google Now; presentando un asistente más interactivo, gracias a la conversación en dos direcciones, y más inteligente.

En mayo del 2018, se presentó la primera extensión de Google Assistant, el cual nos ocupará en el presente trabajo: Google Duplex.

Figura 1 - Flujo de interacción entre el Usuario, Google Assistant y Google Duplex

Duplex permite a Assistant llevar a cabo tareas de forma automática mediante conversaciones naturales imitando la voz humana. En el gran abanico de posibilidades que despliega la extensión tenemos: llamar a una peluquería para reservar una cita, programar una reserva en un restaurante, llamar a comercios para saber su horario, entre otras.

Para evitar posibles problemas durante estas conversaciones, el sistema tiene la capacidad de reconocer situaciones donde no puede continuar e indicarle a usuario que no es capaz de finalizar la tarea.

Dado que debe interactuar con humanos, Duplex incorpora fallas del habla como palabras de relleno o frases comunes, y la posibilidad de modificar la entonación, dotando de “humanidad” a sus interacciones.

DESCRIPCIÓN DE LAS TÉCNICAS DE IA

Recurrent Neural Network

Las RRN son un tipo de redes neuronales artificiales muy utilizadas, tanto en el reconocimiento de la escritura como en el reconocimiento del habla, debido a la capacidad que tienen para poder utilizar su estado interno o memoria para procesar una secuencia de entradas.

Su concepción se basa en el hecho de que “mientras estás leyendo esto” basas la comprensión “de estas palabras” en la compresión de las palabras anteriores y no empiezas de cero para cada palabra nueva que lees.

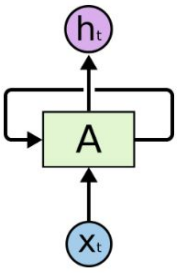

Figura 2 - RNN simple

Una RNN entonces es una red neuronal que como se puede observar en la *Figura 3*, para un input x_t produce un output h_t empleando bucles en el proceso, que le permiten tener “memoria”. El problema de esto último viene dado cuando nos interesa mantener las dependencias a largo plazo. Para ello se han desarrollado las Redes Neuronales LSTM (Long Short-Term Memory), un tipo de RNN que permiten solucionar el problema de las redes recurrente convencionales en cuanto a la brecha que puede existir entre la información relevante y el punto en el que esta se necesita, ya que son capaces de aprender las dependencias a largo plazo.

Las LSTM tienen una estructura en forma de cadena de módulos, donde cada módulo tiene una estructura particular, con unos “neural network layer” y unas operaciones entre ellos determinantes.

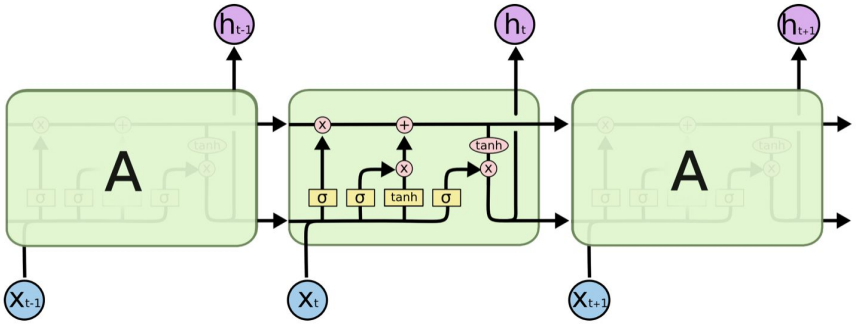

Figura 3 - Red RNN de tipo LSTM

El flujo central de información de las LSTM es la línea horizontal superior que representa el estado de cada célula. Estas redes tienen la capacidad de eliminar/agregar información al estado de la célula mediante las puertas.

Las puertas se componen de una función sigmoide σ que genera valores entre cero y uno, es decir, la cantidad de información que se debe dejar pasar; y la operación puntual de multiplicación $\times$.

El procesamiento interno de una LSTM sigue los siguientes pasos:

- **Forget Gate Layer** (capa σ): Eliminación de información del estado de la célula.
- **Input Gate Layer** (capa σ): Decide los valores que se van a actualizar.
- $tanh$ **layer**: Creación de un vector con nuevos valores candidatos que podrían ser agregados al estado.
- **Combinación de la salida del Input Gate Layer y el** $tanh$ **layer mediante** $\times$: creación de una actualización del estado.
- **Actualización del estado**: se actualiza el estado de la célula anterior C_{t-1} en el nuevo estado C_t; para llevarlo a cabo se multiplica ($\times$) la salida del Forget Gate Layer y se le suma ($+$) la actualización del estado (producto de la salida del Input Gate Layer y el $tanh$ layer)

Finalmente, se **produce la salida de la célula**, que es una versión filtrada del estado actual de esta. Para filtrar la salida se emplea una capa sigmoide σ que decide qué parte del estado vamos a sacar; paralelamente, mediante la función tangente hiperbólica se sitúan los valores del estado entre $[-1,1]$; y finalmente, se multiplican los dos resultados anteriores, de forma que la salida h_t es la escogida, con un valor en $[-1,1]$.

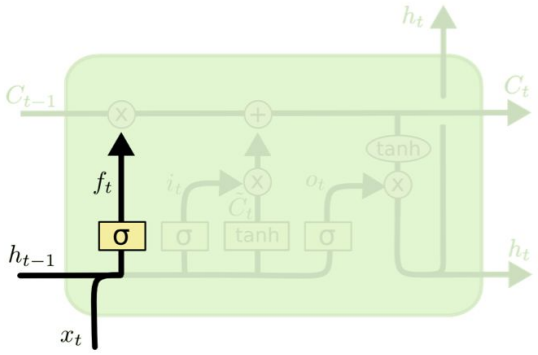

Figura 4 - Forget Gate Layer

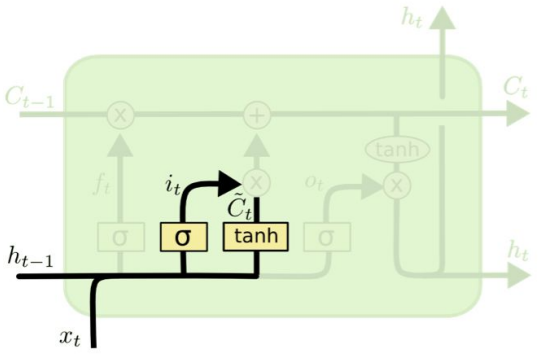

Figura 5 - Input Gate Layer

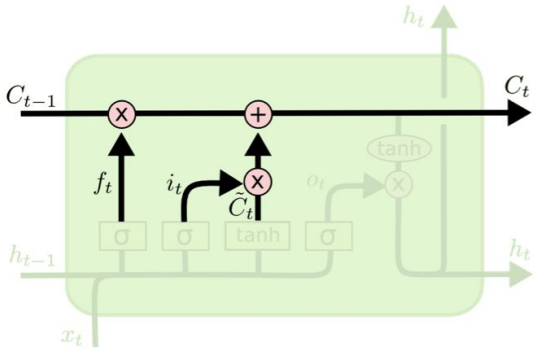

Figura 6 - Actualización del estado

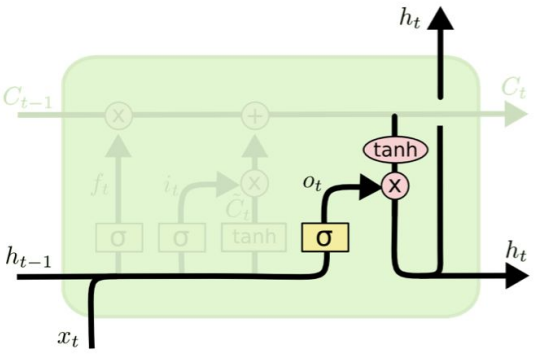

Figura 7 - Producción de la salida

La LSTM expuesta es una versión estándar, pero existen otras. Un ejemplos son unas que agregan “conexiones de mirilla” de forma que las puertas pueden mirar el estado de la célula. Otra posibilidad es acoplar la Forget Gate Layer y la Input Gate Layer, de forma que ambas decisiones se tomen de forma conjunta. Otras que no explicaremos y que están tomando relevancia con el objetivo de explotar la memoria a largo plazo: Gated Recurrent Unit, Depth Gated RNNs y Clockwork RNNs.

Text to Speech: WaveNet

Las RNN son muy buenas reconociendo y generando secuencias de patrones, sin embargo, para la síntesis de voz no es lo más óptimo. WaveNet, usa una red neuronal convolucional (CNN), lo cual es bastante sorprendente ya que las redes neuronales convolucionales no están pensadas para tratar datos que varían con el tiempo.

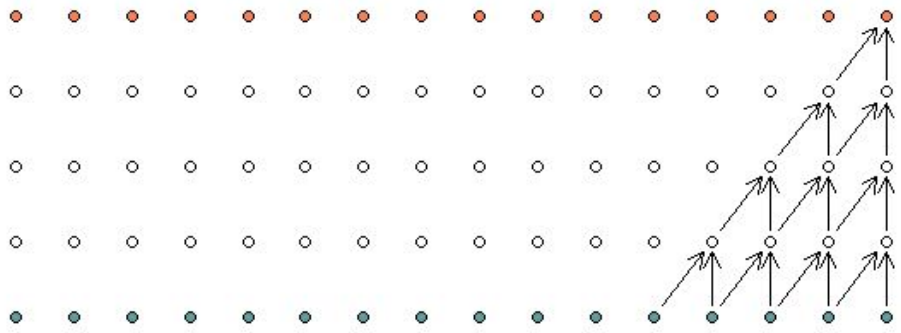

Figura 8 - Convoluciones Causales no Dilatadas

Una red neuronal convolucional pretende aprovechar la información que potencialmente pueden contener aquellos nodos cercanos al nodo que se está tratando. Haciendo una convolución es capaz de unir la información de varios nodos cercanos en un único nodo que representa a todo el grupo.

WaveNet no usa una convolucional normal sino que usa una convolución dilatada. Eso quiere decir que el filtro de la convolución se expande por una área mayor que su longitud. Es decir, que se salta algunos valores pudiendo así obtener información de nodos que están mucho más separados y poder tener así una visión más global de la información.

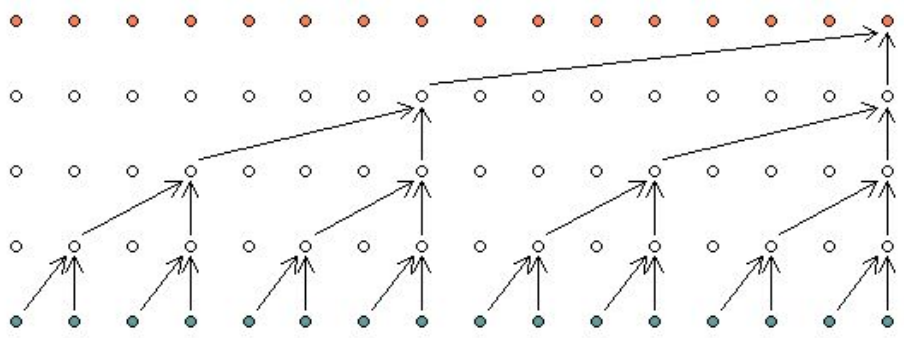

Figura 9 - Convoluciones Causales Dilatadas de WaveNet

WaveNet coge el input (nodos azules) y hace una convolución dilatada hasta generar un output (nodo naranja), pasando así a la siguiente iteración, donde se añade otro nodo de input y si vuelve a repetir la convolución.

Este proceso, hace que se genere la voz a partir de una entrada de texto, sin embargo, se tiene que generar nodo a nodo. No se puede hacer de manera paralela ya que cada iteración requiere de información de los nodos internos anteriores para generar el siguiente nodo interno. Dado que se requieren de 16.000 nodos output para poder generar 1 segundo de audio, este proceso es muy ineficiente.

Para ello, Google modificó la CNN original para poder conseguir más paralelismo y así, mejorar la velocidad del algoritmo. Para ello, generaron otro tipo de CNN que partía de ruido blanco y a cada iteración va refinando la salida de manera que se van ajustando las dependencias entre las muestras vecinas hasta que finalmente queda una síntesis de voz de alta calidad.

Con este pequeño cambio de paradigma, WaveNet, que era capaz de generar 172 muestras por segundo (a 24 kHz, serían 7,167 milisegundos) pasa a ser capaz de generar más de 500.000 muestras por segundo (como es a 24 kHz, serían 20,83 segundos). Esta mejora supone que la red que antes generaba 1 segundo de audio cada 2 minutos y medio pasa a generar 20 segundos de audio por segundo.

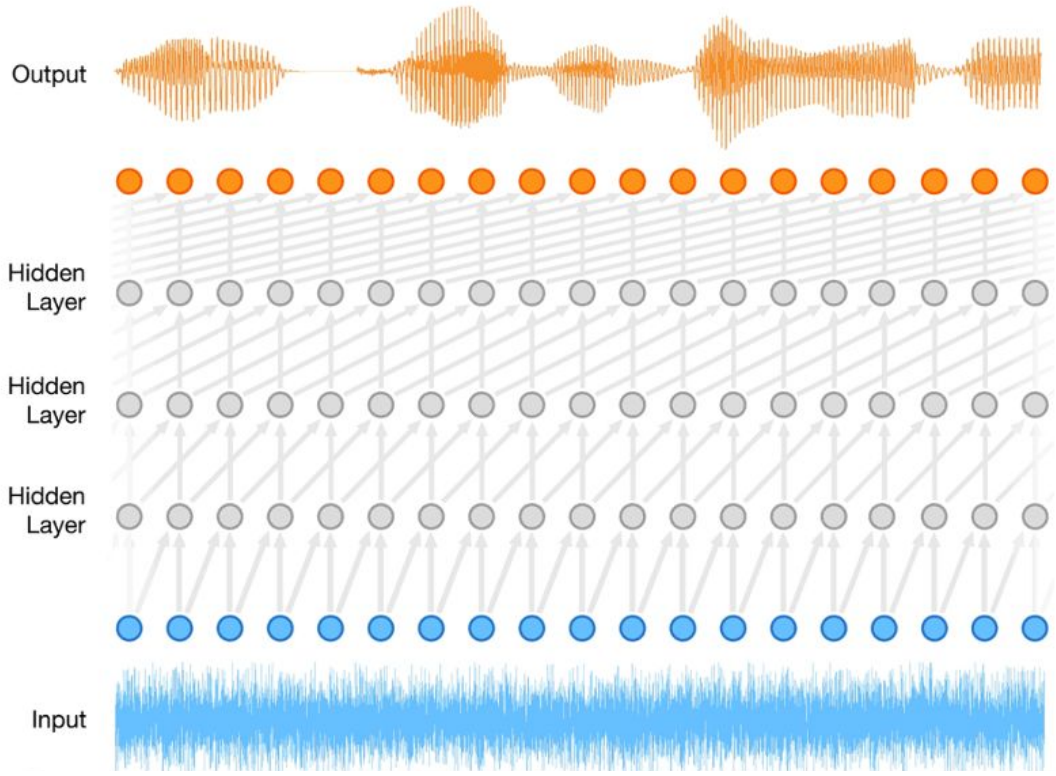

Figura 10 - Proceso Neuronal de WaveNet

En la *Figura 10* podemos ver como la red pasa de ruido blanco a una salida de audio bien definida usando los nodos parciales anteriores.

La manera de entrenar esta red neuronal no es trivial. Para entrenarla, Google usó una técnica muy similar,aunque no idéntica, a las GANs (Generative Adversarial Networks).

En las GANs, básicamente se usan 2 redes neuronales:

- **Red generadora**: Una genera contenido (una imagen, audio, video…)
- **Red discriminadora**: La otra dado un contenido dicta si el contenido generado ha sido generado por la red neuronal 1 o si es un ejemplo verídico.

Durante el entrenamiento, la red generadora intenta engañar a la discriminadora y la discriminadora intenta aprender a diferenciar mejor entre un ejemplo real y uno generado.

WaveNet para entrenar su versión paralela usa un método similar, tiene 2 redes neuronales:

- **Red profesor**: Antigua red capaz de generar voz de manera no paralela.
- **Red estudiante**: Red paralela que intenta imitar la salida de la red profesor pero de manera mucho más eficiente.

A cada iteración la red estudiante se va acercando cada vez más a la salida que daría la red profesor, pero siendo mucho más eficiente.

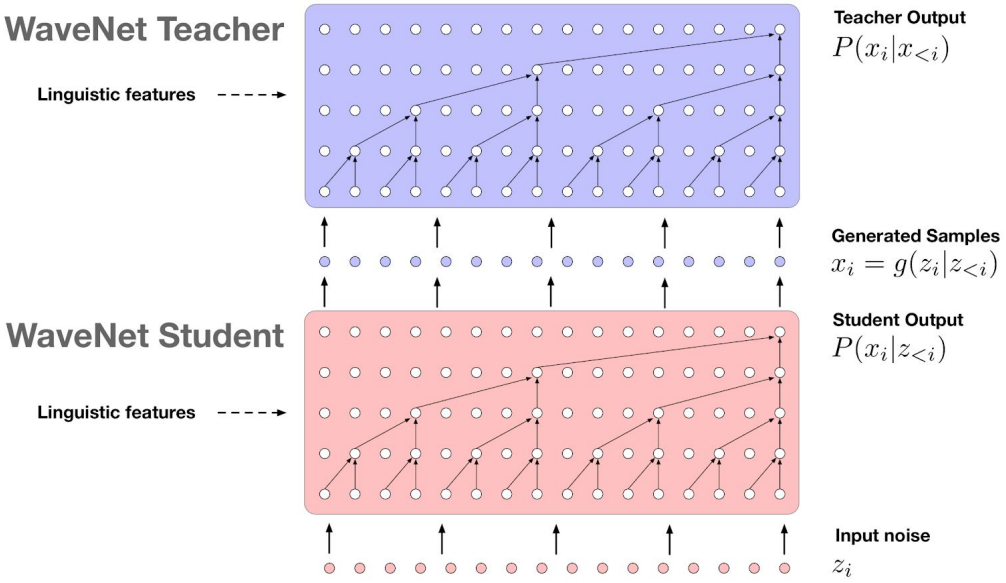

Figura 11 - Entrenamiento de WaveNet

Text to Speech: Tacotron 2

La síntesis de voz de Google Duplex es una evolución del Tacotron 2, el cual es un sistema basado en la unión de técnicas usadas en el Tacotron 1 y WaveNet.

El Tacotron 2 tiene dos componentes principales:

- Como Tacotron 1, una LSTM capaz de transformar una entrada de texto en un espectrograma.
- Una versión modificada de WaveNet capaz de generar una salida de audio a partir de los espectrogramas predichos.

Pasos que ocurren dentro del Tacotron 2:

1. La entrada de texto se representa en un *character embedding* (mapear los caracteres en un espacio n-dimensional) de 512 dimensiones que se pasa a una CNN de 3 capas con 512 filtros de [5 x 1].
2. Está CNN es la encargada de reconocer el contexto a largo plazo en la entrada de los caracteres. La salida de esta CNN se pasa a una LSTM bidireccional de 512 unidades (256 en cada dirección) para generar las *encoded features* (las palabras se codifican de manera que sea más fácil de consumir para la red neuronal).
3. Las *encoded features* se pasan a una red neuronal atencional que se encarga de seleccionar aquellas features que son más relevantes para cada paso de decoder de salida. Se usan diversos parámetros de atención.

4. Los vectores fijos de las features seleccionadas (32 vectores de longitud 31) se pasan a un decoder RNN autoregresiva que será la encargada de predecir el espectrograma de las features, frame a frame.
5. La salida de la RNN se pasa antes por una *pre-net* que contiene 2 capas *fully-connected* de 256 unidades ReLU (activación). La pre-net actúa como cuello de botella esencial para el aprendizaje de la atención.
6. La salida de la pre-net y el vector de contexto se concatena y se pasa a 2 LSTM unidireccionales con 1024 unidades.
7. La concatenación de la LSTM y el vector de contexto se proyectan con una transformación lineal para predecir el frame del espectrograma.
8. Finalmente el resultado, se pasa a una post-net que añade la predicción del frame del espectrograma a la reconstrucción entera resultante.

En la *Figura 12* hay una representación donde se puede observar mejor el flujo de eventos para la generación del espectrograma.

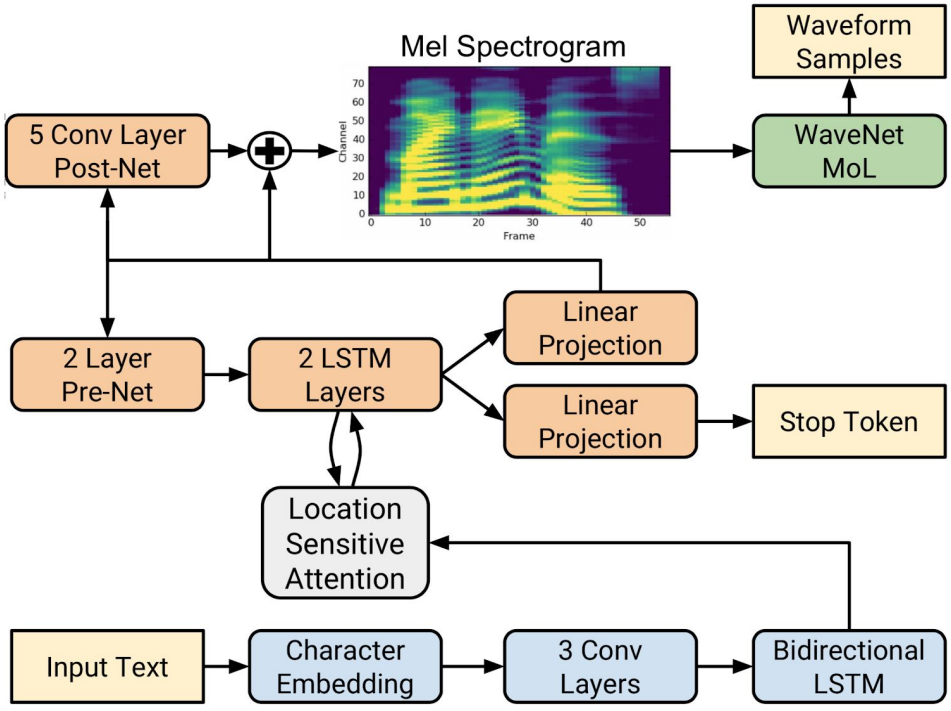

Figura 12 - Flujo de trabajo de Tacotron 2

Finalmente, el espectrograma resultante predicho se pasa a WaveNet que realiza la transformación a voz, tal y como se ha explicado anteriormente.

DESCRIPCIÓN DE LA UTILIZACIÓN DE LAS TÉCNICAS

El principal objetivo sobre el que se construye todo el sistema interno de Duplex es la capacidad para conducir una conversación natural teniendo en cuenta que el lenguaje natural es “duro” de entender, un contexto natural es difícil de modelar y la necesidad de un procesamiento rápido de la información para no perder la sensación de naturalidad.

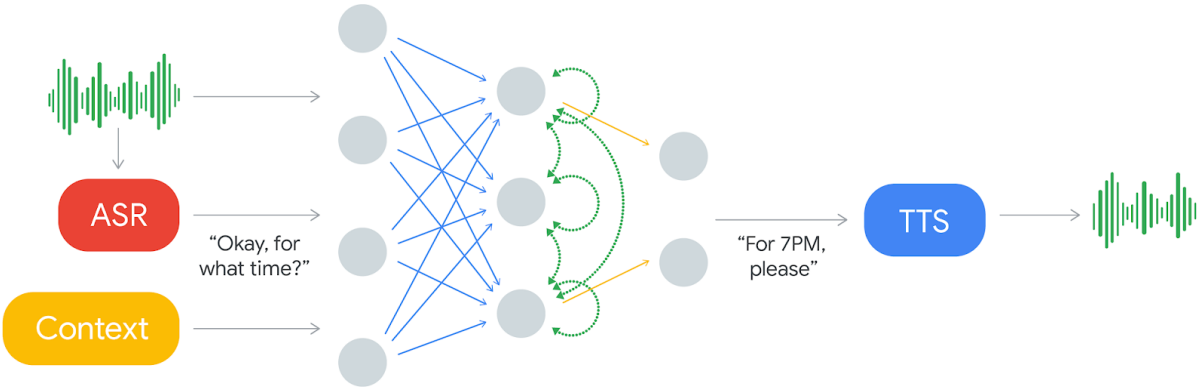

Figura 13 - Flujo de trabajo entre los diferentes módulos de Google Duplex

En la *Figura 13* podemos observar el flujo de trabajo del sistema. En el núcleo de este tenemos una RNN (Recurrent Neural Network) diseñada específicamente para él, mediante TFX (TensorFlow Extended), una plataforma de machine learning end-to-end para la librería open source de ML desarrollada por Google, TensorFlow.

La RNN recibe diferentes inputs que le permiten conducir la conversación de la forma más natural posible:

- Salida de ASR (Automatic Speech Recognition de Google).
- Características del audio.
- Historial de la conversación.
- Contexto (objetivo de la llamada, momento del día, etc).

La salida de la red, es decir, la réplica al antecedente en el flujo de la conversación, es recibida por el módulo TTS (Text To Speech) que cuenta con un **motor de *texto a voz*** y un **motor de *síntesis*** que le permiten controlar la entonación en función de las circunstancias. Para esto último, TTS útiliza Tacotron y WaveNet.

El entrenamiento de la RNN se realizó con un conjunto de dato de conversaciones telefónicas anónimas. Además, fue entrenada separadamente específicamente para cada tarea.

INNOVACIÓN

Explicación de la Innovación

La principal innovación en Google Duplex, puesto que hace mucho que existen sistemas computacionales capaces de realizar llamadas telefónicas e interactuar con la persona que se encuentra al otro lado del teléfono, es que este es el sistema de conversación “más humanizado” hasta la fecha.

Las capacidades de procesamiento de la voz que le ofrece el ASR de Google, la capacidad de modulación fónica realmente cercana a la humana gracias al módulo TTS de la mano de WaveNet, y la RNN implementada mediante TensorFlow específicamente para el sistema; hacen de Google Duplex el sistema automático más capacitado en el mercado y con el habla más natural para las tareas que es capaz de realizar.

Esto último teniendo en cuenta todo lo que se considera un habla natural: interpretación del contexto, modulación correcta de la voz, latencia de respuesta adecuada, uso de expresiones e incorrecciones típicas del habla.

Es destacable también el gran empeño de Google por producir innovación utilizando otras innovaciones recientes, punteras y open source que los diferentes departamentos de la compañía realizan; vease los empleados en Duplex: TensorFlow y WaveNet.

Naturaleza de la Innovación

La naturaleza innovadora de este producto radica esencialmente en la reutilización de técnicas ya existentes pero aportando valor añadido al concebir posibilidades de uso diferentes.

Puesto que estas técnica o bien son bastante reciente o están en constante revisión y mejora, el uso de estas a este nivel ayudar a conseguir un progreso más acelerado de innovación.

IMPACTO SOCIAL

Beneficios

Google Duplex genera o generará un gran impacto en nuestra sociedad. Con respecto a la parte positiva de este impacto, cabe destacar que es una herramienta que claramente simplifica muchas de las actividades del día a día. Tareas tan cotidianas como la de reservar mesa en un restaurante o pedir cita al médico por teléfono ahora pueden quedar delegadas a nuestro asistente personal de Google sin que la persona que está al otro lado del teléfono se percate de ello.

Por otra parte, también podemos considerarlo como un administrador de tareas por el hecho de que permite concertar citas al mismo tiempo que el usuario organiza su tiempo según éstas.

Por el momento, Google Duplex es capaz de realizar tareas como reservar una mesa en un restaurante, encontrar el horario de una tienda y programar una cita para un salón de belleza.

Así pues, este asistente personal es el más completo de todos los existentes hasta el momento, ya que tiene capacidad para administrar más tareas y de forma más eficiente, de forma que dispondremos de más tiempo para dedicarlo a actividades más complejas e importantes.

Riesgos

La parte negativa de este impacto social generado con el lanzamiento de Google Duplex está estrechamente relacionada con la ética. Desde su presentación ha generado polémica por el hecho de hablar por teléfono sin saber si realmente en el otro lado está otra persona o un sistema basado en inteligencia artificial.

Ante el debate desencadenado en la comunidad tecnológica sobre si debería identificarse o no para evitar estafas o engaños, una portavoz de Google ha asegurado que la compañía se asegurará que la herramienta se identifica apropiadamente.

Está claro que estamos en plena revolución informática y que nuestro día a día va a cambiar en los próximos años, así como muchos puestos de trabajo desaparecerán o se transformarán, y aparecerán otros de nuevos. Ya de por sí este hecho es polémico, y más ahora si lo enfocamos a la aparición de Google Duplex.

El lanzamiento del sistema es el inicio de toda una serie de innovaciones que permitirán cambiar empleos o incluso empresas, como los centros de atención al cliente: una inteligencia artificial como la de Google Duplex podría atender las

llamadas y consultas más básicas y recurrentes, mientras que un humano intervendría en situaciones más complicadas.

Esto último actualmente está enfocado como algo negativo, pero entendemos que a largo plazo todo lo que sistemas como Duplex sustituyan no será en vano, y que al fin y al cabo tendrán un impacto positivo en la sociedad.

IMPACTO EMPRESARIAL

Beneficios

Entre los beneficios que Duplex aporta a Google, el que probablemente más destaca es el prestigio que da el hecho de haber sido la primera persona que haya sacado al mercado este tipo de sistema. Más cuando, debido al tipo de innovación que es, se tiene una gran repercusión que da, aún más nombre, si cabe, a una empresa como esta.

A nivel más interno, dado que es una empresa con grandes proyecto de I+D+i, utilizar innovaciones propias y externas para crear más innovación permite a la organización estar en constante evolución mediante la reutilización y mejora de todos sus sistemas.

Desde un punto de vista puramente económico, en la *Figura 14* podemos ver la evolución de la capitalización bursátil de la matriz de Google, Alphabet Inc, desde el 24 de Abril hasta el 21 de Mayo.

Figura 14 - Línea temporal de la capitalización bursátil de GOOGLE en la bolsa de valores NASDAQ

Google presentó Duplex durante la Google I/O que duró del 8 al 10 de Mayo. Como se puede observar en la línea temporal, al inicio de la I/O, el dia 8, Alphabet cerró alrededor de los 1056 puntos. Pero al final del evento la capitalización era de 1116 puntos, marcando un máximo destacable, probablemente influenciado por la expectación entorno a Duplex, entre otros productos presentados por la empresa en el evento.

Riesgos

Los riesgos a nivel empresarial, dado el tamaño de la organización, son mínimos. Más aún, cuando el producto es un subsistema o extensión de otro producto de la compañía incluido en todos los smartphones Android del mercado.

Como se puede suponer, partiendo de las dos premisas anteriores, el impacto económico en la empresa es mínimo y al ser “algo más” dentro de un sistema, será utilizado por aquellas personas que realmente le encuentre utilidad es su vida diaria, no creando gran repercusión el hecho de que sea más o menos utilizado en los porvenires de la compañía.

Posición en el mercado

Puesto que es un sistema totalmente innovador, sin igual en el mercado, este ocupa una posición privilegiada, ya que no debe competir con ningún otro sistema.

Aun así, dado el poco tiempo que lleva en el mercado, y lo “escueto” en capacidades (cantidad de tareas automáticas que es capaz de realizar) es difícil medir y/o prever si realmente será utilizado o se delegará a un segundo plano; y si otras empresas crearán competencia, de forma que Google apueste fuerte por el producto, desarrollandolo a largo plazo.

CONCLUSIÓN

Sin duda alguna Google Duplex, pese a ser simplemente una extensión de un producto más grande, marca una diferencia dentro del mercado de los asistentes virtuales, ofreciendo posibilidades que no existían y explorando nuevos rincones dentro de lo éticamente correcto, discusión tan latente hoy en día en torno a todo lo que tenga que ver con hacer uso de la inteligencia artificial.

Esto último, claramente se debe a que como seres humanos necesitamos un proceso de adaptación y aceptación de cualquier sistema mínimamente intrusivo en nuestra vida diaria.

Es de esperar que esta innovación en asistentes llegue tarde o temprano a otros sistemas y que sea explotado más allá de las 4-5 posibilidades que Duplex ofrece por el momento.

Cabe concluir, que es realmente destacable el hincapié en inversión I+D+i que Google hace, reutilizando innovación propia, ampliandola e incluso haciéndola open source como muchos de sus productos de inteligencia artificial producidos en los últimos años.

BIBLIOGRAFÍA

[1] Google AI Blog: Google Duplex: An AI System for Accomplishing Real-World Tasks Over the Phone,
https://ai.googleblog.com/2018/05/duplex-ai-system-for-natural-conversation.html

[2] Wikipedia: Google Assistant,
https://en.wikipedia.org/wiki/Google_Assistant

[3] Wikipedia: Recurrent Neural Networks,
https://en.wikipedia.org/wiki/Recurrent_neural_network

[4] Wikipedia: Long Short-term Memory,
https://en.wikipedia.org/wiki/Long_short-term_memory

[5] Yan, S. (2016). Understanding LSTM and its diagrams,
https://medium.com/mlreview/understanding-lstm-and-its-diagrams-37e2f46f1714

[6] Olah, C. (2015). Understanding LSTM Networks,
http://colah.github.io/posts/2015-08-Understanding-LSTMs/

[7] Google AI Blog: Tacotron 2: Generating Human-like Speech from Text,
https://ai.googleblog.com/2017/12/tacotron-2-generating-human-like-speech.html

[8] Google AI Blog: Google voice search: faster and more accurate,
https://ai.googleblog.com/2015/09/google-voice-search-faster-and-more.html

[9] DeepMind: WaveNet: A Generative Model For Raw Audio,
https://deepmind.com/blog/wavenet-generative-model-raw-audio/

[10] DeepMind: High-fidelity speech synthesis with WaveNet,
https://deepmind.com/blog/high-fidelity-speech-synthesis-wavenet/

[11] Shen, J., et al (2018). Natural TTS Synthesis by conditioning WaveNet on Mel Spectrogram Predictions,
https://arxiv.org/pdf/1712.05884.pdf

[12] Oord, A., et al (2017). Parallel WaveNet: Fast High-Fidelity Speech Synthesis,
https://arxiv.org/abs/1711.10433

[13] NASDAQ Stock Market Web,
https://www.nasdaq.com/

[14] Europa Press. Google confirma que Duplex se identificará ante los receptores de sus llamadas,
https://www.europapress.es/portaltic/software/noticia-google-confirma-duplex-identificara-receptores-llamadas-20180511110745.html