TRABAJO DE INNOVACIÓN:

SISTEMA DE RECOMENDACIÓN DE *YOUTUBE*

Ibars Cubel, Albert

López Rodríguez, Iván

Santiago Corona, Daniel

Grupo 13

UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

Facultat d'Informàtica de Barcelona

Índice

1. Introducción 2

2. Contexto 3
2.1. Recomendaciones de vídeos 3

3. Descripción de las técnicas de IA 4
3.1. Generación de candidatos 5
3.1.1. Recomendación como clasificación 5
3.1.2. Arquitectura del generador de candidatos 6
3.1.3. Trucos de rendimiento 7
3.2. Clasificación de candidatos 8
3.2.1. Modelado del tiempo de visualización esperado 9

4. Innovación 10

5. Impacto empresarial 11
5.1. Beneficios 11
5.2. Riesgos 11
5.3. Posición en el mercado 12

6. Impacto social 13
6.1. Beneficios 13
6.2. Riesgos 13

7. Conclusiones 14

8. Bibliografia 15

1. Introducción

En el actual documento, nos proponemos estudiar el algoritmo recomendador de videos de YouTube, uno de los sistemas de recomendación más sofisticados y de mayor escala que existen. Describiremos qué es YouTube, describiremos las técnicas de IA empleadas, explicaremos la naturaleza innovadora de este sistema de recomendación y detallaremos el impacto que tiene y tuvo tanto en la empresa como en la sociedad.

La principal motivación que nos llevó a escoger este tema fue el hecho de que todos los integrantes del grupo somos consumidores de esta plataforma y teníamos curiosidad de conocer mejor el famoso "*Algoritmo de YouTube*", cuya efectividad puede ser constatada por cualquier usuario habitual de la plataforma.

2. Contexto

YouTube es la plataforma más grande del mundo para crear, compartir, descubrir y visualizar videos. Fue creado en febrero de 2005 por Chad Hurley, Steve Chen y Jawed Karim, quienes se conocieron trabajando en PayPal. Un año más tarde, YouTube fue adquirido por Google por 1.650 millones de dólares. Actualmente es el segundo sitio web más popular del mundo, justo detrás de Google.

Esta plataforma contaba originalmente con un reproductor online basado en Flash, a partir de 2015 dicho reproductor perdió su soporte para Flash y funciona con HTML5. Una de sus principales innovaciones fue la facilidad para visualizar videos en streaming, es decir, sin necesidad de descargar el archivo. Los usuarios, por lo tanto, pueden seleccionar qué video quieren ver y reproducirlo al instante. Asimismo, los usuarios pueden almacenar sus propios vídeos de manera gratuita y sin límite aparente en cantidad.

2.1. Recomendaciones de vídeos

Gracias a la incorporación de recomendaciones de videos de YouTube ha ayudado a más de mil millones de usuarios a descubrir diariamente contenido personalizado en una plataforma donde el constante aumento de vídeos haría extremadamente complicado que los usuarios pudieran encontrar vídeos de su interés en un océano de material audiovisual.
Recomendar videos en una plataforma como YouTube es extremadamente desafiante por tres razones principales:

- *Enorme magnitud de vídeos*: Muchos algoritmos de recomendación existentes han demostrado funcionar bastante bien en problemas pequeños, pero en escala de YouTube no funcionan. Manejar toda la enorme base de datos es algo desafiante.
- *Equilibrar las sugerencias entre material consolidado y material de nueva incorporación*: YouTube contiene una base de datos de videos muy dinámica, cada segundo se suben a la plataforma muchas horas de video. *Cada minuto se suben 300 horas de video a YouTube (2019)*. Por esa razón, el sistema de recomendaciones debe ser lo suficientemente receptivo para modelar el contenido recién subido, así como las últimas acciones tomadas por el usuario.
- *Ruido*: El comportamiento histórico de los usuarios es intrínsecamente difícil de predecir debido a la escasez y a una variedad de factores externos no observables. Por lo que supone una gran cantidad de ruido en los datos. El historial de vídeos puede verse gravemente modificado por ejemplo, por factores como más de una persona compartiendo el perfil.

El problema básico se plantea como "*dado el historial de actividades de YouTube de este usuario: ¿Qué videos son más propensos a ver a continuación?*".

El motivo de querer resolver este problema es que Youtube obtiene sus beneficios a partir de la publicidad que sus usuarios consumen antes, durante y después de la reproducción de sus vídeos. Así que conseguir que el usuario encuentre, empiece a ver y se quede viendo el vídeo son los objetivos principales de Youtube.

3. Descripción de las técnicas de IA

La arquitectura del sistema recomendador (Figura 1) se encarga de seleccionar de entre un conjunto masivo de millones de videos, a un subconjunto de estos con una cardinalidad muchísimo más reducido, unos cientos de vídeos denominados candidatos, que tras pasar un proceso de ránking son puntuados y solo unas docenas de ellos (los que consigan la mayor puntuación) serán escogidos para ser mostrados al usuario.

La *generación de candidatos* toma los eventos del historial de actividad de usuario así como otros datos como los datos demográficos de este como entrada, y devuelve un pequeño subconjunto de cientos de videos. Estos candidatos, respecto a los millones de videos como entrada, están destinados a ser en general relevantes para el usuario con alta precisión.

El *ranking* (clasificación) toma los cientos de videos de la salida de la red de generación de candidatos y devuelve "los mejores" en una lista reducida de docenas de vídeos. Así, logra esta tarea asignando una puntuación a cada video de acuerdo con una función objetivo deseada utilizando muchas características que describen el vídeo y el usuario. Los videos con la puntuación más alta se presentan al usuario, clasificados por su puntuación.

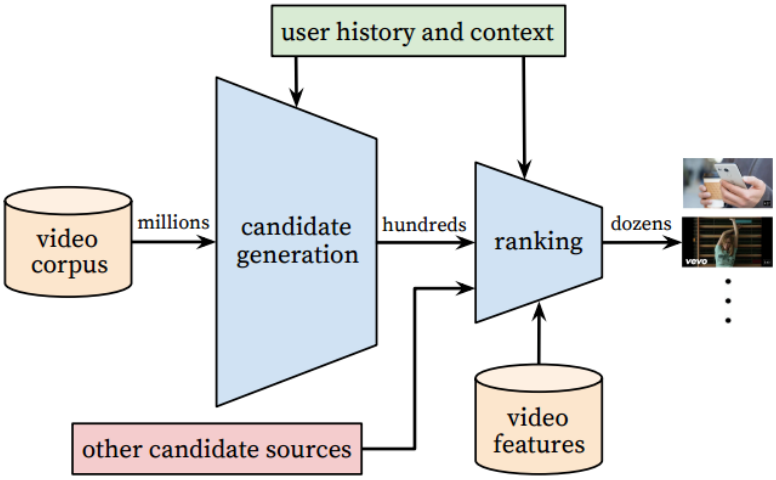

Figura 1: Arquitectura del sistema de recomendaciones

Este enfoque de recomendación en dos etapas permite hacer recomendaciones de un corpus muy grande (millones) de videos asegurándose así que la pequeña cantidad de videos que aparecen en los dispositivos son personalizados y atractivos para el usuario.
A continuación entraremos con más profundidad a explicar estas dos componentes del sistema y el uso redes neuronales en ellos.

3.1. Generación de candidatos

Como se ha dicho anteriormente esta red reduce de millones a cientos de videos que pueden ser relevantes para el usuario. Las primeras iteraciones de la red neuronal se basaban en una factorización matricial entrenada bajo pérdida de rango, este comportamiento de factorización solo integraban las visitas anteriores del usuario. A grandes rasgos esta técnica es un tipo de filtrado colectivo, una técnica utilizada en los sistemas recomendadores que permite hacer predicciones sobre los intereses de un usuario utilizando los intereses o preferencias colectivas de un conjunto muchísimo más grande de usuarios. La premisa en esta técnica es que si una persona A tiene la misma opinión que la persona B en algún aspecto, la persona A tiene más probabilidades de estar de acuerdo con el sujeto B en un algún otro aspecto que con cualquier otra persona escogida al azar.

3.1.1. Recomendación como clasificación

YouTube plantea el problema de generación de candidatos como un *problema de clasificación multiclase extrema*, donde la clasificación multiclase es la familia de problemas que requieren responder preguntas con múltiples respuestas donde existe incertidumbre acerca de si realmente existe más de una pregunta correcta. El adjetivo extremo se refiere a que dicho problema debe lidiar con un número de opciones que escapa las posibilidades de los algoritmos tradicionales en la clasificación tradicional , que se situaba originalmente alrededor de las 5000 opciones, mientras que en nuestro caso se sitúa en los millones.

El problema de predicción se convierte en "clasificar con precisión la visualización $w(t)$ de un video i en un momento t", para determinados videos i de un recopilatorio V, dado un contexto C, y el usuario U.

$$P(w_t = i|U, C) = \frac{e^{v_i u}}{\sum_{j \in V} e^{v_j u}}$$

Figura 2: Probabilidad de la distribución del tiempo de reproducción.

dónde $u \in \Re^N$ representa un *embedding* de dimensión alta del usuario junto al contexto y el $v_j \in \Re^N$representa el *embedding* de cada video candidato. En este entorno, un *embedding*, o incrustación en español, es un mapeo de entidades dispersas (*videos inviduales, usuarios, etc.*) en un vector denso en $\Re^N$. La tarea de la red neuronal profunda es aprender a generar configuraciones u del usuario en función del historial y contexto que son útiles para discriminar entre vídeos con un clasificador softmax (asignando probabilidades a las salidas y escogiendo la mayor).

3.1.2. Arquitectura del generador de candidatos

La arquitectura del modelo sigue un enfoque tradicional de "torre", donde la parte inferior de la red (o la más cercana a la entrada) es la capa más ancha, y cada capa a partir de entonces reduce a la mitad el ancho de la red. La generación candidata se inspira en una bolsa continua de modelos de lenguaje de palabras utilizadas en vectores de palabras. El vector de entrada combina el historial de reproducción, el historial de búsqueda, las características demográficas y geográficas del usuario.

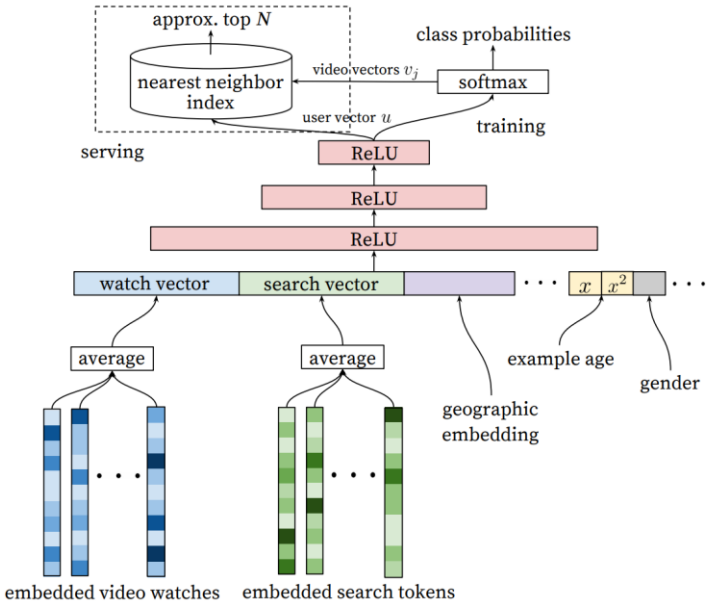

Figura 3: Arquitectura de modelo de generación de candidatos que muestra características dispersas integradas concatenadas con características densas.

Para calcular el subconjunto '*watch vector*' de la entrada, se asigna una secuencia de IDs de video a una secuencia de incrustaciones (las incrustaciones de vídeo se aprenden conjuntamente con todos los demás parámetros del modelo) y, a continuación, simplemente se promedian. La capa de entrada va seguida de varias capas de unidades lineales rectificadas (ReLU) totalmente conectadas.

El modelo se entrena mediante muestreo negativo, donde intentamos reforzar los resultados negativos propagando sólo un subconjunto de estos ejemplos negativos en lugar de todos, y apuntamos a la relación entre ejemplos negativos para reforzar esta correlación. En el momento de servir, se utiliza un algoritmo aproximado de vecinos más cercanos para servir los Nresultados superiores en tiempo sublineales.

3.1.3. Trucos de rendimiento

Tanto en la generación de candidatos como en las redes de clasificación de candidatos, los desarrolladores aprovecharon varios trucos para ayudar a reducir la dimensionalidad o el rendimiento del modelo.

En primer lugar, entrenaron a una subred para transformar características dispersas (como ID de vídeo, búsquedas e ID de usuario) en entidades densas al aprender una incrustación para estas características. Esta incrustación se aprende conjuntamente con el resto de los parámetros del modelo a través del descenso de gradiente.

En segundo lugar, los sistemas de aprendizaje automático pueden mostrar un sesgo implícito hacia el pasado, dado que están capacitados en datos históricos. Para corregir esto, la edad de un ejemplo de entrenamiento se incluye como una característica durante el entrenamiento y al realizar predicciones se establece en cero. Esto hace una gran diferencia como se muestra en la figura 4, la línea azul muestra las predicciones del modelo sin la característica de edad y la línea roja con ella. La línea verde es la distribución real.

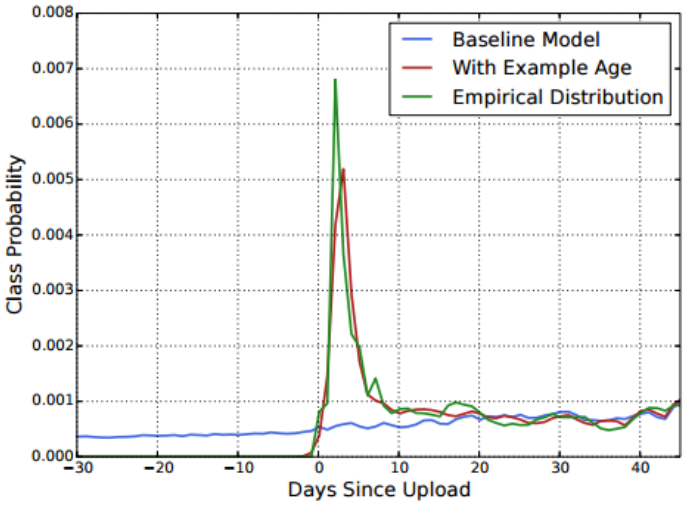

Figura 4: Comparación sobre la probabilidad de clases, con y sin la característica “edad de ejemplo”.

3.2. Clasificación de candidatos

El proceso de clasificación (ranking) funciona con muchos menos videos (cientos) de candidatos, producidos por la primera fase. Por lo tanto, es factible aprovechar muchas más características que describen el vídeo y la relación del usuario con él. Se utiliza una red neuronal profunda con una arquitectura similar a la generación de candidatos para asignar una puntuación independiente a cada vídeo mediante la regresión logística. Luego, la lista de videos se ordena por puntuación y se devuelve al usuario, donde los vídeos con mayores puntuaciones serán seleccionados para ser mostrados.

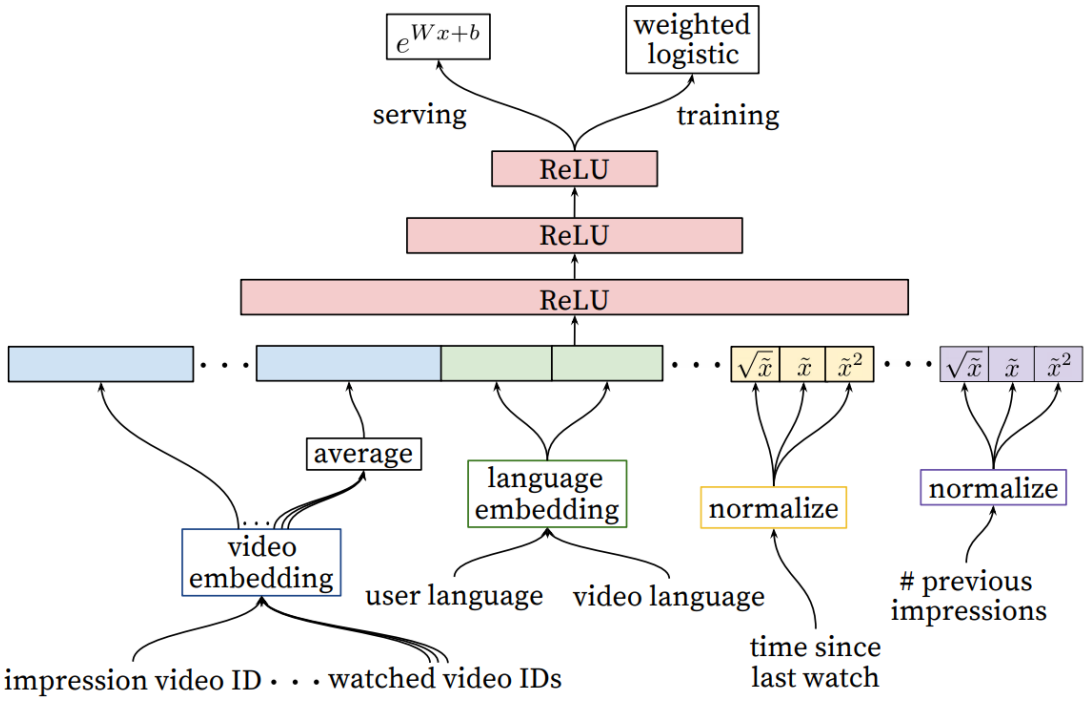

Figura 5: Arquitectura de red de clasificación profunda que muestra características categóricas integradas con integraciones compartidas y características continuas normalizadas.

Los modelos de clasificación utilizan cientos de características, y todavía se gastan considerables recursos de ingeniería transformando los datos de usuario y video en características útiles.
El objetivo general del modelo de clasificación es predecir el tiempo de reproducción esperado dados ejemplos de entrenamiento que son positivos (se hizo clic en el video) o negativos (no se hizo clic en el video). Los ejemplos positivos se anotan con la cantidad de tiempo que el usuario pasó viendo el vídeo.
En cuanto a las características continuas, se normalizan de dos maneras:

- Sigue la normalización estándar entre [0,1) utilizando una distribución uniforme acumulativa.
- Además de la normalización estándar x, también se alimentan los formularios $sqrt(x)$ y x^2. Esto permite al modelo crear funciones sublineales de cada entidad, lo que es crucial para mejorar la precisión sin conexión.

3.2.1. Modelado del tiempo de visualización esperado

Para predecir el tiempo de reproducción esperado, se utiliza regresión logística. Las miniaturas de vídeos clickeadas se pesaron con el tiempo de reproducción observado, mientras que los ejemplos negativos todos recibieron peso unitario. En la práctica, esto modeló una probabilidad $E[T](1 + P)$, donde $E[T]$modela el tiempo de reproducción esperado, y Pmodela la probabilidad de hacer clic en el video.

Hubo una demostración del impacto de una red más amplia y profunda en la pérdida por usuario. La pérdida por usuario fue la cantidad total de tiempo de reproducción mal predicho, frente al tiempo total de reproducción de los datos retenidos. Esto permite que el modelo prediga algo que sea como proxy para una buena recomendación; en lugar de predecir una buena recomendación en sí.

Hidden layers	weighted, per-user loss
None	41.6%
256 ReLU	36.9%
512 ReLU	36.7%
1024 ReLU	35.8%
512 ReLU $\rightarrow$ 256 ReLU	35.2%
1024 ReLU $\rightarrow$ 512 ReLU	34.7%
1024 ReLU $\rightarrow$ 512 ReLU $\rightarrow$ 256 ReLU	34.6%

Figura 6: Efectos de redes más amplias y profundas en los datos de retención del día siguiente.

Se puede observar que las redes más anchas y más profundas tienden a disminuir la pérdida considerablemente, esto es un resultado esperado porque a mayor anchura y profundidad en las capas de redes neuronales, más complejas pueden ser las funciones que codifican, a costa de pagar un precio en el coste computacional aumentado de entrenarlas. YouTube optó por implementar el último modelo.

4. Innovación

Tal y como se cita en el artículo original de Google sobre el sistema recomendador, en el momento en el que se ideó el algoritmo había escasa documentación sobre el uso de redes neuronales profundas para el uso de sistemas recomendadores.

Aunque ya existían algunas aplicaciones de las redes neuronales en sistemas recomendadores como recomendadores de noticias para captar a los usuarios por los titulares según sus preferencias o ideología (referencia [12]), el uso a gran escala de las redes neuronales profundas estaba aún por ser utilizado, y Google (o su empresa matriz Alphabet) fue y es una pionera en la implementación de tecnologías que utilizan redes neuronales.

El hecho de que no se hubieran utilizado aún podría deberse a que existían técnicas ya consolidadas que no requieren del uso de redes neuronales, ni el coste computacional que éstas llevan asociadas, como la factorización de matrices.
Tal y como se expone en la referencia [11], a grandes rasgos las diferencias entre un modelo lineal como el generado por la factorización de matrices, funcionara de manera muy satisfactoria recomendando o clasificando correctamente información que ya se ha repetido en nuestros datos o son instancias que ya se han tratado o planeado como tratar, mientras un modelo no lineal como el generado por redes neuronales profundas puede conseguir mejores resultados en situaciones donde se pueda extrapolar información en los datos que poseemos y con los que hemos entrenado, para después tratar situaciones o instancias distintas a las vistas durante ese proceso.

Tal y como comentamos en el apartado de contexto, este es precisamente uno de los comportamientos que requerimos de un algoritmo de recomendación para Youtube, donde el flujo de nuevo contenido es constante y muy grande, además de ser muy diverso en naturaleza y por lo tanto difícil de catalogar.

Durante la implementación del sistema recomendador utilizando redes neuronales, se utilizó Google Brain, un *framework* creado por Google utilizado para diseñar e implementar arquitecturas de redes neuronales profundas en un entorno de computación distribuido. Algo antes de la publicación del artículo original sobre el algoritmo recomendador, Google Brain fue hecho *open-source* bajo el nombre de **TensorFlow**, uno de los *frameworks* más relevantes para el desarrollo de modelos de redes neuronales artificiales hoy en día.

Así, la innovación tecnológica en el sistema recomendador es indudable. Pero el impacto del desarrollo de un sistema recomendador tan eficaz en el mayor proveedor de material audiovisual de Internet vas más allá de la innovación tecnológica, como explicaremos en los siguientes apartados, el sistema recomendador de Youtube ha influenciado de gran manera a la industria del entretenimiento, tanto a sus competidores como a la forma en que los creadores presentan su contenido, siempre buscando crear contenido que sea atractivo para el algoritmo. Sin embargo, como veremos no podríamos hablar del sistema recomendador de Youtube sin comentar sus sombras y polémicas en la sociedad.

5. Impacto empresarial

El impacto empresarial de la implementación del algoritmo recomendador se ha reflejado en un aumento de ingresos para Google. Para explicarlo brevemente, en el momento que un usuario busca un video, dicho algoritmo tratará de recomendarnos videos similares, por tanto hay una gran probabilidad de que veamos algún video más. Al ver más videos, más anuncios se reproducirán y más beneficios obtendrá Google.

5.1. Beneficios

Como ya hemos comentado brevemente, la implementación del algoritmo recomendador, ha influido en un mayor beneficio para la empresa. El beneficio más claro es el hecho de estar generado mayores ingresos, ya que se reproduce un mayor número de anuncios.

Por otra parte nos encontramos con que fueron pioneros al desarrollar un algoritmo usando redes neuronales para un sistema de recomendación. Actualmente existen otras grandes empresas que también utilizan algoritmos de recomendación como por ejemplo Spotify o Netflix.
Cuantas más herramientas innovadoras disponga la empresa, en una mejor posición se encontrará. Como Google siempre ha tratado de innovar con nuevas funcionalidades, o como mínimo, igualarse a la de sus competidores, siempre se ha encontrado en el top de empresas más valoradas.

Como una de las grandes fuentes de ingresos son los anuncios, y al acabar la reproducción de un video vamos a recomendar videos que se asimilan, es altamente probable que el usuario lo vea, reproduciendo así más anuncios. Como bien podemos ver en el artículo [8] de la bibliografía, Youtube generó un total de 15 billones de dólares americanos tan solo con los anuncios, pero es muy probable que sin la ayuda del algoritmo recomendador no hubieran generado tales ingresos.

5.2. Riesgos

Los riesgos a nivel empresarial de la aplicación del algoritmo pueden darse por los riesgos a nivel social. Es decir, si el algoritmo recomienda algo inapropiado para el usuario, se refleja en una pérdida de lo que podría haber sido una mayor cantidad de anuncios reproducidos.

Otro de los puntos que les puede suponer un riesgo, es la discusión sobre si el algoritmo es ético, ya que está tratando de seducir al usuario para mantenerlo en su plataforma, consiguiendo así un mayor beneficio. Pero como bien sabemos, la mayoría de las empresas tratan de llegar al máximo público posible y mantenerlo activo el mayor tiempo posible, ya que se reflejará en una mayor visibilidad de la empresa, y con ello, un mayor beneficio, que es lo que realmente buscan las empresas.

5.3. Posición en el mercado

Google siempre ha sido una empresa que se ha encontrado entre el top 20 de las empresas más importantes del mundo, con la compra de Youtube que hizo en 2006, siendo esta una de las primeras plataformas para poder compartir videos mundialmente, se aseguró una gran fuente de ingresos.

Al inicio, Youtube no generaba una gran cantidad de beneficios, de hecho tal como se comenta en el artículo [10] de la bibliografía, en 2014, Youtube género lo suficiente para entrar en el punto de equilibrio, es decir, generó lo suficiente para que el beneficio de ese año fuera nulo, pero al menos no tuvieron pérdidas.

El impacto del algoritmo de recomendación fue positivo para la empresa, aunque hay que tener en cuenta que no fue el único factor que ha influido en el crecimiento de la empresa, ya que el algoritmo de recomendación es solo una más de entre todas las funcionalidades y/o herramientas de las que dispone.

Como ya hemos comentado, el algoritmo de Youtube fue uno de los primeros sistemas de recomendación que salieron al mercado, colocándolos así en una buena posición en el mercado. Ahora, en cambio, el uso de sistemas de recomendación se ha normalizado entre el resto de empresas.

6. Impacto social

Lo primero que debemos recordar sobre YouTube es que es una plataforma para compartir videos cuya principal fuente de ingresos es la publicidad, por lo que mientras más tiempo pasas viendo videos, más ingresara Google por publicidad, por lo que tanto las recomendaciones de YouTube como los creadores de contenido les interesa maximizar el tiempo que los usuarios están viendo videos. La incorporación de IA en el sistema de recomendación de YouTube ayudará a mantener al usuario en la plataforma, la integración de esta IA contiene sus beneficios y riesgos en la sociedad.

6.1. Beneficios

Las recomendaciones de Youtube son responsables del 70% del total de reproducciones de la plataforma. Como beneficios podemos encontrar los siguientes:

- Proporciona videos potencialmente interesantes y relacionados. Proporciona un ciclo de reacción en tiempo real para poder satisfacer los distintos intereses de cada espectador.
- Descubrir nuevos contenidos de entretenimiento.
- Como ejemplo de usuarios que utilizan YouTube para escuchar música, la plataforma recomendará canciones del artista que están escuchando, pero también de otros artistas con estilo musical similar. Facilitando así la búsqueda y accesibilidad para el usuario.

6.2. Riesgos

Las recomendaciones de YouTube han sido acusadas de ser tóxicas, ya que el problema es que la Inteligencia Artificial (*que usa YouTube para sus recomendaciones*) no está desarrollada para ayudar a conseguir lo que quieres, está creada para que te vuelvas adicto a YouTube. Surge así una serie de riesgos:

- Difusión de videos que promueven la desinformación o bulos, haciendo que el espectador se envuelva en un halo de desinformación, que pueden dar cabida a teorías de la conspiración como quienes defienden que la Tierra es plana o que niegan el Holocausto.
- Algunos análisis sugieren que este enfoque generalmente privilegia los videos más "*extremos y controvertidos*", que de acuerdo con un estudio publicado en "*Data & Society*" pueden empujar a las personas a un profundo agujero de contenido y a la radicalización política.
- El funcionamiento podría conducir a los usuarios pedófilos a videos de menores llevando a cabo actividades cotidianas. En ellos, a través de la sección de comentarios, los adultos se organizaban formando redes pedófilas de bajo nivel.
- Recomendaciones de videos con escaso valor, que han sido recomendados por una llamativa miniatura o título, como es comúnmente llamado 'clickbait'.

A raíz de estos riesgos se criticó mucho al algoritmo de YouTube, que tuvo que esforzarse para regular estos sucesos y mejorar así su plataforma.

7. Conclusiones

Como bien ya comentamos en la introducción, los integrantes del grupo somos consumidores de la plataforma Youtube y nos llamaba la atención cómo podría funcionar el algoritmo de recomendación de Youtube. Por eso mismo la recolección de información y el estudio de las diferentes técnicas utilizadas para el algoritmo ha sido ameno.

De alguna manera podíamos imaginarnos cómo funciona el algoritmo aproximadamente, como tal la idea resumida es sencilla, a partir de los videos que ves, se recomendarán vídeos similares. Sin embargo, no conocíamos muchas de las técnicas que se aplican, como por ejemplo la función de activación ReLU.

Como el tema a escoger era de libre elección, es una buena forma de que el alumnado elija un algoritmo que le interese, y a parte de conocer el funcionamiento del propio algoritmo, aprender diferentes técnicas más avanzadas (o que al menos no hemos visto en el curso) que se utilizan en la inteligencia artificial.

8. Bibliografia

[1] Pau Covington, Jay Adams, Emre Sargin. *Deep Neural Networks for YouTube Recommendations* (Septiembre 16, 2016). https://research.google/pubs/pub45530/ [Consulta: Octubre 22, 2020]

[2] Amir Jaffari. *How the YouTube Algorithm Works (Or Why Your Videos Aren't Getting Views)* (Julio 4, 2019). https://www.shopify.com/blog/youtube-algorithm [Consulta: Octubre 28, 2020]

[3] Moin Nadeem. *How YouTube Recommends Videos* (Julio 5, 2018). https://towardsdatascience.com/how-youtube-recommends-videos-b6e003a5ab2f [Consulta: Octubre 22, 2020]

[4] Abhishek Kumar. *YouTube's Recommendation Engine: Explained* (Enero 30, 2020). https://hackernoon.com/youtubes-recommendation-engine-explained-40j83183 [Consulta: Noviembre 2, 2020]

[5] Matt Gielen & Jeremy Rosen. *Reverse Engineering The YouTube Algorithm: Part I* (Junio 23, 2016). https://www.tubefilter.com/2016/06/23/reverse-engineering-youtube-algorithm/ [Consulta: Novimebre 2, 2020]

[6] Matt Gielen. *Reverse Engineering The YouTube Algorithm: Part II* (Febrero 16, 2017). https://www.tubefilter.com/2016/06/23/reverse-engineering-youtube-algorithm/ [Consulta: Novimebre 2, 2020]

[7] Revathi Prakash. *Implementing the YouTube Recommendations Paper in TensorFlow - Part 1* (Junio 25, 2020). https://theiconic.tech/implementing-the-youtube-recommendations-paper-in-tensorflow- part-1-d1e1299d5622 [Consulta: Noviembre 15, 2020]

[8] Paige Leskin. *Youtube ad revenue was 9 times more than Google paid to buy it* (Febrero 4, 2020). https://www.businessinsider.com/youtube-advertising-revenue-9-times-google-acquired-video-platform-2020-2 [Consulta: Noviembre 2, 2020]

[9] Microsoft Research Blog Team. *Everything you always wanted to know about extreme classification (but were afraid to ask)* (Febrero 12,2020). https://www.microsoft.com/en-us/research/blog/everything-you-always-wanted-to-know-about-extreme-classification-but-were-afraid-to-ask/ [Consulta: Diciembre 19, 2020]

[10] Victor Lukerson. A Decade Ago, Google Bought Youtube. (Octubre 10, 2016) https://www.theringer.com/2016/10/10/16042354/google-youtube-acquisition-10-years-tech-deals-69fdbe1c8a06 [Consulta: Diciembre 19, 2020]

[11] Google Inc. Wide & Deep Learning for Recommender Systems. (June 24, 2016) https://arxiv.org/pdf/1606.07792.pdf [Consulta: Diciembre 20, 2020]

[12] K. Oh, W. Lee, C. Lim and H. Choi. "Personalized news recommendation using classified keywords to capture user preference,". (2014) https://ieeexplore.ieee.org/document/6779166 [Consulta: Diciembre 20, 2020]